本文档界定和覆盖范围：
1、细化拆解 Aaas 验证平台的工作事项和计划
2、产品侧作为验证平台的上游输出，定义好给测试团队的标准数据和交付物
3、梳理并定义清楚上下游工作边界和关键指标输出
4、定义好 Aaas 输入输出格式标准：观测存储标准、数据集标准、评测集标准
5、技术方案和观测工具的技术方案设计

*总体目标

围绕核心目标：支撑 2027 年底 KA 客户 5 万卡销售量
■ Agent 核心验证场景：AI Coding、百万长上下文（多 Agent）、视频理解、视频生成
■ Agent 场景化负载场景的还原，围绕几个深度场景验证-定好验证目标、测试高效完成验证支撑。
■ Agent 验证平台的定义和输出，包含可观测指标平台，沉淀在 Aaas 层，输出对外场景统计指标，效果指标，成本指标，性能指标，最佳实践实践在自研算力的资源分配。
■ 持续调研、挖掘行业内领先的主要 Agent 范式场景，并还原部署（模拟千卡、万卡集群、高并发，高流量的场景），输出验证指标

*Aaas 价值与定位

AaaS 验证平台的核心价值，核心定位是：芯片商用前质量出口，即以“NGU800 芯片是否满足商用”为验证出发点，围绕芯片商用的重点目标场景(如 AI Coding、长上下文、视频理解、视频生成等重点场景等)，系统性还原 Agent 在不同算力与集群环境下的真实任务负载，形成可量化、可复现、可对比的验证体系。
第一方面是为芯片的商用决策提供质量验证方面的依据
第二方面是为自研芯片在 Agent 场景下的性能优化、成本优化和瓶颈定位提供依
第三方面是方面为 KA 客户提供前置验证能力，支撑方案设计和 PoC 落地。
核心输出在于构建真实场景、沉淀验证标准、打通全链路观测，并持续输出面向芯片、平台和客户的高价值验证报告。 AaaS 验证平台定位：面向芯片商用目标，Agent 粒度场景的**系统化验证与评估平台，验证自研芯片在主流 Agent 场景下可商用性问题(包括不限于效率、成本、稳定性等)。深度理解并还原 Agent 在真实场景下、不同集群算力上的任务负载特征，形成可量化、可复现、可对比的验证体系，并形成面向内部优化和外部客户验证的标准化能力** 内部验证核心价值： 1.为芯片可商用化提供质量出口真实依据 芯片在目标商用场景(以 Agent 为粒度)的效率，成本 ，稳定性等各个质量维度的量化数据 2.为芯片与平台优化提供真实依据：帮助判断：自研芯片在 Agent 场景下是否真正高效 与其他先进算力相比差距在哪里 哪些场景最值得优先突破 3.真实 agent 场景建模者：负责把行业中的 Agent 场景，从概念层面转化为可部署、可运行、可测

量的真实负载模型。帮助公司理解下一代 AI 工作负载。 4.芯片与平台能力的放大器：通过验证平台，把“芯片能力、推理框架能力、集群调度能力、网络存储能力”拉通到同一套场景中验证。帮助团队内部及时发现短板、定位瓶颈、指导优化优先级。 5.支撑未来大客户场景适配、PoC 设计和方案销售 **Aaas 目标：验证自研芯片在 Agent 场景下的效率、稳定性问题** 平台围绕重点 Agent 场景进行部署、还原、监测和压测，输出一整套关键验证数据，为以下两类目标服务：内部目标：指导自研芯片在 Agent 场景下的优化方向与能力建设 外部目标：支撑 KA 客户在 Agent 场景中的前置验证和方案沟通 1、先完成 Aaas 在先进算力（A800、910B、4090）的验证，包括通用 Agent 部署、监测工具选型部署、模型部署、场景数据集收集与构造、 定义好观测链路日志的标准数据格式和存储方案。 2、进一步部署 coding Agent 场景，完善标准的 BenchMark 和 Case 数据集，结合 Maas 平台的监测数据，进一步细化存储 Agent 运行的全流程链路的轨迹数据。开始在内部先进算力进行验证（X6000s）。 3、持续调研、挖掘行业内领先的主要 Agent 范式场景，还原部署（模拟千卡、万卡集群、高并发，高流量的场景），输出验证指标报告。

*Aaas 与 Maas 的分工边界

*团队分工

PM：蔡杭洲、康锦涛
Test：张勇俊、赵通、陈程
核心职责：验证不同场景的 Agent 在自研集群推理可行性和性能指标，深度调研第三方开源工具和测试框架，挖掘 Agent 场景（Coding/视频生成/多 Agent），内部不关心 Agent 工程化内容，但是整体 Agent 效果指标是前提条件，但不是关键指标。核心关注运行在推理集群的效率指标。

*重点覆盖场景

- 百万长上下文（Multi-Agent）
- Al Coding（Coding-Agent）
- 视频理解（视频多模态理解）
- 视频生成（组合/参考生成、局部修改、轨道补全）

***Agent 评估流程步骤**

暂时无法在飞书文档外展示此内容

一：Aaas 验证平台（验证管理载体）

Aaas 验证平台定位

1、统一纳管不同行业场景的 Agent 应用，并管理 Agent 环境。
2、管理并存储不同 Agent-Case 每次完成评测数据集任务相关的节点时序日志和结构化数据
3、管理评测集（评测 Agent 任务）、验证集数据（基础对话数据集）、评测比对历史版本管理
4、Agent 可观测指标的报告输出
5、标准化对接 Mass 的 API 接口管理，用于对接内部和外部 Maas 平台进行验证测试
6、里面会集成 Langfuse（可观测 Tool）、压测框架
7、E2E 自动化测试

Aaas 验证平台架构

暂时无法在飞书文档外展示此内容

Aaas 验证平台功能清单

一级分类	模块	功能	展示	描述	功能平台集成
应用	应用管理	Agent 应用管	列表		

一级分类	模块	功能	展示	描述	功能平台集成
		理			
		新建Agent应用	应用详情		
评估管理	评测数据集管理	评测集管理列表		评测集是一个精心设计的标准化测试数据集，用于系统化地评测 AI Agent 的性能。评测集通常包含输入样本和预期输出。输入样本作为评估对象的输入数据，预期输出提供了评估基准。 • **输入数据：**提供给评测对象的标准化测试输入，用于评估其在不同场景下的表现。 • • **预期输出（可选）：**理想的输出结果，作为评估基准，作为某些评估器的参考输入。 •	
		创建评测集		1、名称 2、描述 3、配置列： 指定输入样本列配置/指定数据集中期望输出列配置	

一级分类	模块	功能	展示	描述	功能平台集成
				• **名称**：输入列名称。必须以英文字母开头，支持添加字母、数字和下划线。 • • **数据类型**：选择一种数据类型。通过校验数据类型，避免导入数据不匹配的情况，保证评测的数据质量；同时可以提高数据的消费和存储成本。 • • **查看格式**：选择一种渲染评测数据的格式，提高数据的可读性和维护性。 • • **描述信息**：提供描述信息，帮助评测对象理解这个输入数据。 •	
		添加测	本地导入	根据模板导入数据	

一级分类	模块	功能	展示	描述	功能平台集成
		试数据/导入	手动添加	支持添加单独数据项字段	
		修改评测集	修改评测集数据	可以在评测集**草稿**状态下，修改评测集的列配置。 可以在评测集**草稿**状态下，修改评测集数据。	
		评测集版本管理	版本管理	用于满足持续迭代评测数据以提高数据质量。 • **数据完备阶段：**完成测试数据导入后，可提交首个测试版本并关联实验任务，系统将基于该版本进行全量评估。 • • **评估验证阶段：**通过实验报告分析当前版本的数据表现，定位待优化数据样本。 • • **优化升级阶段：**根据评估结果修正数据集后，提交升级版本并重新关联实验，开启新一轮验证循环。 •	

一级分类	模块	功能	展示	描述	功能平台集成
			新建评测集版本	在添加测试数据后，单击**提交新版本**。	
			查看评测集历史版本	**版本记录**区域会显示全部已提交的版本，单击一个目标历史版本，就可以切换到该评测集的历史版本。 不支持修改历史版本的测试集数据。	
	评估管理	创建评估任务			
		实验比对			
		评估结果			
API对接	API管理				
Agent可观测	监控详情运行时总览	运行总览	Runtime数	AgentKit 中创建的 Runtime 总数。提供 Runtime 列表，支持查看 Runtime 相关详细信息。	
			会话数	指定时间段内存在调用的会话总数。提供监控看板，方便查看数据趋势。	
			Token 消耗数	指定时间段内调用大模型消耗的 Token 总数，包含输入和输出 Token 数量。	
			调用数	指定时间段内所有 Runtime 实例的调用数。提供监控看板，方便查看数据趋势。	

一级分类	模块	功能	展示	描述	功能平台集成
			错误数	指定时间段内发生的失败请求总数。	
			错误率	指定时间段内失败请求数占总调用数的比例，错误率 = 错误数 / 调用数。提供监控看板，方便查看数据趋势。	
		运行时监控	CPU 耗时	当前 Runtime 实例在指定时间段内某个时刻消耗的 CPU 时间，包括：用户态 CPU 耗时和内核态 CPU 耗时。CPU 耗时可直观反映当前运行时的执行效率。	
			CPU 使用率	当前 Runtime 实例在指定时间段内某个时刻的 CPU 使用率总和。如果当前运行时同时使用多个 CPU 核心进行计算，最终结果可能大于 100%。	
			内存使用	当前 Runtime 实例在指定时间段内某个时刻的内存使用情况，包括：RSS 内存（Resident Set Size）和 VMS 内存（Virtual Memory Size）。内存使用趋势可用于检测内存分配、识别内存溢出等。	
			GC 对象数量	当前 Runtime 实例在指定时间段内某个时刻的 GC 对象数量，表示垃圾计数器每一代自上次垃圾回收后新增的对象数量，目前分别统计第 0、1、2 代的 GC 对象数量。结合内存数据可用于评估系统稳定性，预防系统崩溃。	
			线程数量	当前 Runtime 实例在指定时间段内某个时刻的线程数量，线程数量趋势可用于发现线程资源瓶颈、优化线程并发度。	

一级分类	模块	功能	展示	描述	功能平台集成
			上下文切换数量	当前 Runtime 实例在指定时间段内某个时刻的上下文切换数量，包括：Voluntary 切换数和 Involuntary 切换数。可结合 CPU 使用情况，分析系统运行性能，优化线程调度等。	
		会话分析	分析列表	可通过 Runtime 名称、会话 ID、用户 ID、耗时等条件进行会话筛选。会话列表支持查看会话相关基础信息，包括：会话 ID、耗时、Total Tokens、Input Tokens、Output Tokens、调用链数、用户 ID、开始时间等。	
			会话详情	可查看每条调用链的开始时间、Input、Ouput 详细信息，以及 Total tokens、调用链数，调用链 ID、用户 ID、模型名称等详细信息。	
		Trace 分析	**Span 列表**	展示 Runtime 相关 Trace 列表及上报量趋势，支持通过 Span 属性、Trace ID、模型名称等多维度筛选；可按 Token 数（总 / 输入 / 输出）、开始时间、耗时排序，快速定位错误和慢查询。	
			性能分析	聚合筛选后的链路列表，展示各节点耗时数据及分布，帮助定位性能瓶颈；需至少填写 Span 类型、Runtime 名称、接口名三个筛选条件。	
			错误传播分析	聚合筛选后的链路列表，分析错误节点的传播源头及上下游影响，可视化错误影响面和根源；需至少填写 Span 类型、Runtime 名称、接口名三个筛选条件。	

一级分类	模块	功能	展示	描述	功能平台集成
			单链路详情	可查看当前链路追踪相关的服务以及大模型数据，例如：大模型调用 QPS、大模型调用次数、Token 使用量、大模型响应耗时、TTFT、TPOT 监控看板。	
		日志分析	**Runtime 日志**	Runtime 运行过程产生的日志，可用于运行过程的故障排查和行为追踪。提供分词检索，以及通过 Runtime 名称、日志级别、Trace ID 进行数据筛选。	
			Runtime 构建日志	通过持续交付流水线构建 Runtime 过程的日志，可用于构建过程的故障排查和行为追踪。	
	记忆库分析	Memory 分析	API 调用次数	指定时间段内通过 SDK 调用记忆库相关操作的总次数。	
			平均延迟	指定时间段内通过 SDK 调用记忆库操作的平均响应时间。	
			总错误率	指定时间段内通过 SDK 调用记忆库操作中发生错误的比例，总错误率 = 错误操作数 / 总操作次数。	
		监控详情	单链路详情	可查看当前链路调用模型的基础数据，例如：Input/Output 数据，Request 的系统、模型、类型，Response 的模型、Input 缓存命中 Token、Input Token 消耗、Output Token 消耗、总 Token 消耗。	
	知识库分析	分析概览	API 调用次数	指定时间段内通过 SDK 调用知识库相关操作的总次数。	
			平均延迟	指定时间段内通过 SDK 调用知识库操作的平均响应时间。	

一级分类	模块	功能	展示	描述	功能平台集成
			总错误率	指定时间段内通过 SDK 调用知识库操作中发生错误的比例，总错误率 = 错误操作数 / 总操作次数。	
		知识库监控详情	Trace 分析	可查看当前相关 Trace 列表和 Trace 上报量趋势，支持通过 Span 属性、Trace ID、模型名称、Span 类型、AI Span 类型、接口名等进行数据筛选。除此之外，还支持按照 Total Tokens、Input Tokens、Output Tokens、开始时间和耗时进行排序，用于快速定位错误和慢查询	
	会话分析	会话分析列表	分析列表	可通过 Runtime 名称、会话 ID、用户 ID、耗时等条件进行会话筛选。会话列表支持查看会话相关基础信息，包括：会话 ID、耗时、Total Tokens、Input Tokens、Output Tokens、调用链数、用户 ID、开始时间等。	
		会话详情中	**调用链 ID**	可查看当前链路调用模型的基础数据，例如：Input/Output 数据，Request 的系统、模型、类型，Response 的模型、Input 缓存命中 Token、Input Token 消耗、Output Token 消耗、总 Token 消耗。	
	Trace 分析调用链详情	**链路详情可视化展示**	接口维度展示	瀑布图将对展示内容进行精简，只有调用角色为 Server 或 Consumer 的 Span 会被展示。该展示方式从服务端以及消费者的角度衡量应用性能，在调用关系比较复杂时，可以从链路中快速提取重要的信息。在使用接口维度展示的情况下，可以在**接口名称**列点击绿色⊕符号，在弹出的对话框中查看该应用的所有调用。	

一级分类	模块	功能	展示	描述	功能平台集成
			全链路展示	瀑布图将展示该链路的所有 Span。通过全链路展示，可以更全面的了解链路中每个环节的细节。	
			查看鸟瞰图	体现链路中的关键环节的调用耗时。在调用关系比较复杂的时候，通过鸟瞰图可以更快速的掌握链路的全貌。在鸟瞰视图开启的情况下，可以单击页面右上方的**收起鸟瞰图**关闭鸟瞰视图。	
		Span 列表	列表	可查看所有 Trace 列表和 Trace 上报量趋势。支持通过 Span 属性、Trace ID、模型名称、Span 类型、AI Span 类型、接口名等进行数据筛选。除此之外，还支持按照 Total Tokens、Input Tokens、Output Tokens、开始时间和耗时进行排序	
		Trace ID 详情	**LLM 数据**	可查看当前链路调用模型的基础数据，例如：Input/Output 数据，Request 的系统、模型、类型，Response 的模型、Input 缓存命中 Token、Input Token 消耗、Output Token 消耗、总 Token 消耗。	
			LLM 指标	可查看当前链路追踪相关的服务以及大模型数据，例如：大模型调用 QPS、大模型调用次数、Token 使用量、大模型响应耗时、TTFT、TPOT 监控看板。	
		性能分析	耗时分布	可查看聚合服务接口某时间段内符合筛选要求的链路列表，获得调用链中各个节点的耗时数据，可视化展示耗时分布和链路耗时列表，方便用户快速定位性能瓶颈点。至少完善	

一级分类	模块	功能	展示	描述	功能平台集成
				Span 类型、Runtime 名称、接口名 3 个筛选后即可获取性能分析数据。	
		错误传播链分析		可查看聚合服务接口某时间段内符合筛选要求的链路列表，获得错误节点的可能传播源头以及上下游节点影响，可视化展示错误影响面分析和错误源分析，方便用户快速分析错误的传播情况	
		Span 导出	导出关键指标		
性能观测	性能分析	性能指标	LLM 调用次数	统计指定时间范围内，应用发起的 LLM 服务调用总次数，直观反映 LLM 应用的业务访问热度。	
			LLM 调用平均耗时	指定时间内所有 LLM 调用的总耗时除以调用次数，是衡量 LLM 服务整体响应效率的基础指标。	
			LLM 调用耗时	将指定时间内的 LLM 调用耗时按升序排列后，第 99 百分位对应的耗时值，反映 99%的调用不会超过的耗时上限，用于评估极端场景下的性能。	
			LLM 调用耗时	按升序排列所有 LLM 调用耗时后，第 95 百分位对应的耗时值，代表 95%的调用耗时不超过该数值，体现大部分场景下的性能稳定性。	
			LLM 调用耗时	又称中位数耗时，按升序排列所有 LLM 调用耗时后，第 50 百分位对应的耗时值，反映 LLM 调用的平均性能基准水平。	
			模型调用次数	统计指定时间内，LLM 模型的调用总次数，体现模型的实际使用频率。	

一级分类	模块	功能	展示	描述	功能平台集成
			首 Token 平均耗时	从发起 LLM 调用到接收返回的第一个 Token 的平均时间，是衡量 LLM 响应即时性的核心指标，直接影响用户交互体验。	
			模型调用平均耗时	指定时间内大模型调用总耗时除以模型的调用次数，用于衡量模型的整体运行效率。	
			模型调用错误率	指定时间内模型调用失败的次数占总调用次数的比例，直观反映 LLM 模型服务的稳定性与可用性。	
			Token 使用	统计指定时间内 LLM 调用过程中输入 Token 与输出 Token 的总数量（或分别统计），是计算模型使用成本与评估资源消耗的关键指标。	
LLM 观测	模型监控	监控指标汇总	模型调用总次数	调用指定模型的总次数。	
			模型调用平均耗时	调用指定模型的平均耗时。	
			模型调用错误次数	调用指定模型失败的次数。	
			Token 使用总量	指定模型 Token 消耗总量（input + output）。	
			模型调用次数	调用指定模型的次数趋势。	
			模型调用平均耗时	调用指定模型的平均耗时趋势。	
			模型调用错误	调用指定模型失败的次数趋势。	

一级分类	模块	功能	展示	描述	功能平台集成
			Token 使用量	指定模型 Token 消耗总量（input + output）趋势。	
			模型调用 Runtime 排行（TOP5）	调用指定模型次数排名前 5 的运行时列表。	
			模型调用平均耗时 Runtime 排行（TOP5）	调用指定模型平均耗时排名前 5 的运行时列表。	
			模型调用错误 Runtime 排行（TOP5）	调用指定模型错误次数排名前 5 的运行时列表。	
			Token 使用 Runtime 排行（TOP5）	调用指定模型消耗 Token 排名前 5 的运行时列表。	
			模型请求耗时分位数	调用指定模型耗时分位数 P99/P90/P75/P50。	
			TTFT 分位数	调用指定模型返回首包数据的平均耗时分位数 P99/P90/P75/P50。	
			TPOT 分位数	调用模型在首个 Token 输出后，后续输出每个 Token 所需的时间分位数。	

一级分类	模块	功能	展示	描述	功能平台集成
工具调用观测	工具分析	数据概览	工具数量	指定时间段内查询到的工具总数。提供工具列表，可查看工具清单和工具相关基础信息。	
			调用数	指定时间段内所有工具的调用数量。提供调用数趋势图，方便了解不同时间段内工具的使用频率，合理规划资源。	
			错误数	指定时间段内工具调用失败的数量。	
			错误率	指定时间段内工具调用失败的错误率，错误率 = 错误数 / 调用数。提供错误率趋势图，方便检测系统稳定性，保障用户体验。	
			平均响应时间	指定时间段内调用工具的平均响应时间，平均响应时间 = 所有工具调用的响应时间之和 / 调用总数。提供平均响应时间趋势图，方便进行性能评估和服务质量保障。	
		工具详情	**Trace 分析**	可前往单链路详情查看当前工具相关的完整链路和 Trace 完整日志。	
数据看板	数据洞察	Agent 总览	AI 应用	选择链路数据来源时必填。选择目标 AI 应用。	
			AgentKit 调用数（分布）	通过环形图形式展示指定时间段内的 AgentKit 调用数分布情况。	
			AgentKit 调用数据趋势图	指定时间段内的 AgentKit 调用数趋势图，可用于流量分析、异常检测、性能优化等。	

一级分类	模块	功能	展示	描述	功能平台集成
			AgentKit 会话数趋势图	指定时间段内的 AgentKit 会话数趋势图，可用于异常行为分析等。	
			AgentKit 调用平均延时	指定时间段内的 AgentKit 调用平均延时统计，可用于性能分析、系统优化等。	
			AgentKit 调用错误率	指定时间段内的 AgentKit 调用错误率统计，可用于健康度检查、故障排查等。	
		Agent 执行分析	执行步数	通过饼图形式统计指定时间段内 Agent 不同流程的执行步数，可用于检查执行效率和资源消耗等。	
			Token 分布	通过饼图形式统计指定时间段内 Agent 的 Token 分布，可用于成本控制检查和上下文利用率度量。	
			耗时分布	通过饼图形式统计指定时间段内 Agent 的耗时分布，可用于性能分析和用户体验分析。	
		工具分析	工具调用次数	指定时间段内所有工具的调用次数和趋势分析。	
			工具调用 Token	指定时间段内所有工具的调用 Token 数和趋势分析。	
			工具调用耗时	指定时间段内所有工具的调用耗时和趋势分析。	
			工具调用次数 - 分工具	分工具展示指定时间段内所有工具的调用次数和趋势分析，可根据实际需求显示或隐藏部分数据和图表。	
			工具调用	分工具展示指定时间段内所有工具	

一级分类	模块	功能	展示	描述	功能平台集成
			Token - 分工具	的调用 Token 数和趋势分析，可根据实际需求显示或隐藏部分数据和图表。	
			工具调用耗时 - 分工具	分工具展示指定时间段内所有工具的调用耗时和趋势图,可根据实际需求显示或隐藏部分数据和图表。	
		记忆分析	工具调用次数	指定时间段内记忆库工具的调用次数和趋势分析。	
			工具调用Token	指定时间段内记忆库工具的用Token 数和趋势分析。	
			工具调用耗时	指定时间段内记忆库工具的调用耗时和趋势分析。	
		知识库工具分析	工具调用次数	指定时间段内知识库工具的调用次数和趋势分析。	
			工具调用Token	指定时间段内知识库工具的用Token 数和趋势分析。	
			工具调用耗时	指定时间段内知识库工具的调用耗时和趋势分析。	

二：BenchMark 与 Case 数据集（输入）

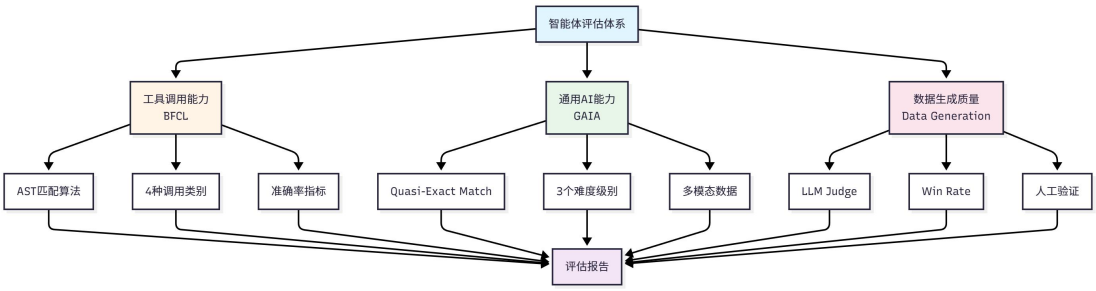

核心目标：围绕千卡、万卡集群的 Infra 规模，应该构建自己的评测集： 考验测试 Agent 在集群运行上性能、成本、效率的使用情况。核心还是解决智能体评测与 KA 现实应用间存在巨大鸿沟。
自建 Agent 和集群性能评测体系旨在为 内部提供标准化评估工具，帮助其量化评估智能体性能、成本、能力、可以对比不同解决方案并制定实施路径。

核心输出-针对性能效率的 BenchMark 体系文档（脚本脚手架、数据集、Moniter、参考结果、判决器、调度器）
① 评测体系构建，客观、准确、全面的评估模型真实价值并驱动模型/产品优化，产出评估报告。
② 设计一套测试 LLM 输出质量的标准：定义指标、设计测试用例、建自动化工作流
③ 细化到到对硬件整体算力使用效果的理想态定义和评测体系的构建；持续迭代/完善评估体系，包括但不限于评估方法论、标准、Benchmark 与指标口径等，对模型效果与关键业务指标负责。
④ 建立 badcase 机制与问题归因框架，推动问题定位、方案设计、验证上线与线上监控闭环，持续提升算力集群的可用性、稳定性与可控性。
⑤ 定义性能/评测数据标准、流程及效果衡量指标，保障模型迭代的科学性与有效性。

2.1、评测指标与开源 BenchMark 汇总

Benchmark 的核心由 3 部分组成：数据集、工作负载、度量指标。

推理性能基准测试-BenchMark-内部核心构建

五大核心性能指标

1.

首 Token 延迟：反映系统初始响应速度，行业标杆：≤2 秒（中等长度文本），影响因素：P 节点负载、KV Cache 计算

2.
3.

吐字率(Token/s)：反映文本生成效率，行业标杆：≥40 Token/s，计算公式：吐字率 = 输出 Token 数/(结束时间-首 Token 时间)

4.
5.

QPM：系统吞吐能力，计算公式：QPM = 成功请求数/(测试时长/60)

6.
7.

输入 Token 数：影响计算复杂度，包括：System 指令+用户问题+上下文历史

8.
9.

输出 Token 数：影响生成时间，测试时需保持不同测试轮次输出量级一致

10.

性能基准测试	简介	能力类型	核心测试能力	镜像
EvalScope 模型推理性能压测框架	一套“可比、可复现、可扩展”的压测方案	推理压测	支持多并发场景下的吞吐量、延迟、稳定性等核	https://evalscope.readthedocs.io/zh-cn/latest/user_guides/stress_test/quick_start.html

性能基准测试	简介	能力类型	核心测试能力	镜像
			心指标测试。可模拟真实业务负载，验证模型服务在不同上下文场景下的性能表现	

性能基准测试	简介	能力类型	核心测试能力	镜像
MindIE Benchmark	昇腾的专门评测框架-能够测量并记录模型在各个阶段的推理耗时（HW内部生态闭源	推理压测	支持端到端的推理测试	https://www.hiascend.com/document/detail/zh/mindie/100/mindieservice/servicedev/mindie_service0151.html

性能基准测试	简介	能力类型	核心测试能力	镜像
	框架，仅用于参考比对）			

Agent-BenchMark

评测集名称	数据集简介	能力类型	核心测试能力	镜像
GAIA基准	GAIA（General AI Assistants）是由Meta AI和Hugging Face联合推出	通用能力评估：通用AI助手能力评估	• 多步推理：将复杂问题分解为多个子问题 • • 知识运用：利用内置知识和外部知识库 • • 多模态理解：处理文本、图片、文件等多种输入	https://huggingface.co/datasets/gaia-benchmark/GAIA

评测集名称	数据集简介	能力类型	核心测试能力	镜像
	的评估基准，专注于评估AI助手的通用能力		• • 网页浏览：从互联网获取最新信息 • • 文件操作：读取和处理各种格式的文件 •	
BFCL-v4基准	函数调用能力评估基准	工具调用能力评估，UC Berkeley推出，包含1120+测试样本，涵	1. 理解任务需求：从用户的自然语言描述中提取关键信息 2. 3. 选择合适工具：从可用工具集中选择最适合的工具 4. 5. 构造函数调用：正确填写函数名和参数 6. 7. 处理复杂场景：支持多函数调用、并行调用等高级场景	https://github.com/ShishirPatil/gorilla.git 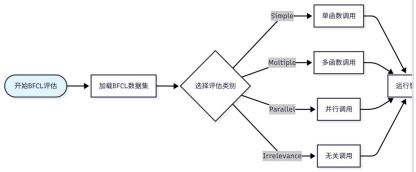

评测集名称	数据集简介	能力类型	核心测试能力	镜像
		盖simple、multiple、parallel、irrelevance四个类别，使用AST匹配算法评估，数据集规模适中，社区活跃。	8. 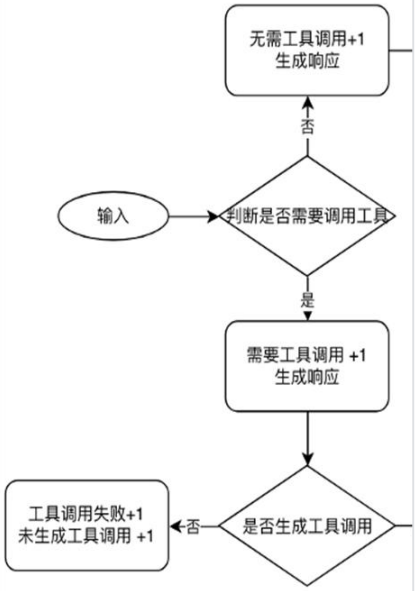 	

评测集名称	数据集简介	能力类型	核心测试能力	镜像
Multi Agent Bench	用于评估多智能体系统在多种交互场景中的协作与竞争能力	评估多Agent系统的团队表现，衡量协作、竞争质量	任务成功率 正确的函数调用使用 高级 BFCL 评测 吞吐量/延迟变化 任务分配准确性 协调成功率 通信开销：跟踪每个任务的消息数量，以防止新增 Agent 导致过多的协调成本，从而拖慢系统。	

评测集名称	数据集简介	能力类型	核心测试能力	镜像
Agent Board	通过细粒度的能力拆解、轨迹回放和可视化分析，帮助深入理解和优化 AI Agent 的行为表现	Agent 轨迹回放与环境模拟	• Success Rate（任务成功率）：衡量 Agent 在规定最大交互步数内“完全达到”环境目标的比例 • • Progress Rate（进度率）：衡量 Agent 在多步任务中已完成子目标的比例，反映累进式推进能力 • • Grounding Accuracy（落地准确率）：衡量 Agent 在每步操作（如点击、API 调用）中生成“合法、可执行”动作的比例，用于评估动作的有效性及环境交互质量 • • 维度能力评分 AgentBoard 进一步将 Agent 能力拆解为以下六大维度，并分别打分： • • Memory（记忆）：长程上下文信息的利用能力	

评测集名称	数据集简介	能力类型	核心测试能力	镜像
			• • Planning（规划）：将整体目标分解为可执行子目标的能力 • • World Modeling（建模）：推断并维护环境隐状态的能力 • • Retrospection（回顾）：基于环境反馈自我反思并修正行为的能力 • • Grounding（落地）：生成有效动作并成功执行的能力 • • Spatial Navigation（空间导航）：在需要移动或定位的任务中，高效到达目标的能力 • •	

评测集名称	数据集简介	能力类型	核心测试能力	镜像
			难度分层分析 • • Easy/Hard Breakdown：分别统计“易”“难”子集上的 Success Rate 与 Progress Rate，帮助识别在不同难度样本上的性能差异 • • 长程交互趋势 •	
Agent Bench	衡量大语言模型（LLM）驱动的Agent 在多场景下的泛化能力和实际表现	通用能力评估清华大学推出，包含8个不同领		

评测集名称	数据集简介	能力类型	核心测试能力	镜像
		域的任务，全面评估智能体的通用能力。		

AI Coding-BenchMark

评测集名称	数据集简介	能力类型	核心测试能力	镜像
SWE-bench	用于评估大型语言模型（LLMs）在软件工程任务中性能的基准测试套件。它包含各	代码生成		https://www.swebench.com/

评测集名称	数据集简介	能力类型	核心测试能力	镜像
	种编程挑战，涵盖从代码生成到调试和优化的多个方面			
OctoCodingBench	MiniMax 开源的编程基准	系统性代码生成	**压力测试：多重指令冲突与记忆干扰。包含 72 个精心设计的测试用例，覆盖 Python、Java、C++ 等多语言。每个用例都针对一个特定的「过程遵循」场景**	https://www.huggingface.co/datasets/MiniMaxAI/OctoCodingBench
Coding Agent				

视频多模态理解-BenchMark

评测集名称	数据集简介	能力类型	镜像
MMBench-Video	评估大视觉语言模型(LVLMs)的视频理解能力	多样化视频、26 种细粒度能力测试、GPT-4 自动评估	mmbench-video.github.io
Video-MME	全面评估多模态大模型的综合视频理解能力	视频时长广泛（11 秒至 1 小时）、整合字幕和音频模态、覆盖 6 大领域 30 个子领域、全人工标注	video-mme.github.io
Thinking-in-Space	视频 3D 视觉空间智能评估	3D 场景重建、空间定位与估计、时空任务	thinking-in-space.github.io
MVBench	通用视频理解基准	静态+动态任务、多选问答自动转换、多	huggingface.co/datasets/OpenGVLab/MVBench

评测集名称	数据集简介	能力类型	镜像
		场景覆盖	

视频生成-BenchMark

评测集名称	数据集简介	能力类型	核心测试能力	镜像
VBench-2.0	VBench-2.0 是 VBench 系列的升级版本，由上海人工智能实验室等机构联合开发。其核心目标是： 评测维度深化：从传统技术指标（如时序一致性）扩展到更复杂的语义真实性（如物理合理性、常识推理）。	综合视频生成评估基准测试	• 视频生成	
VMBench	VMBench 专注于评估视频生成模型在运动质量上的表现，尤其关注物理合理性和人类感知对齐。其目标是通过结构化评测体系，揭示模型在生成复杂运动（如人体动作、物体交互）时的短板，为优化提供方向。	评估视频生成模型在运动质量上的表现	• 内在真实性 • 基准评估 • 物理常识	

评测集名称	数据集简介	能力类型	核心测试能力	镜像
			• • 人类保真度 •	

2.2、评测集-自定义格式标准

前置工具 EvalScope

模型评测与性能基准测试框架：EvalScope，内置多个业界认可的测试基准和评测指标：MMLU、CMMLU、C-Eval、GSM8K ，支持模型推理性能压测

评测数据格式的存储与流转技术标准

Hugging Face 等平台目前已将所有大型数据集自动转换为 Parquet 格式 。Parquet 的列式存储结构允许评估框架在进行特定维度评估（如仅分析 reasoning_content 字段)时,无需读取整个文件,从而极大地节省了显存和 I/O 开销 。

- **数据分片（Sharding）**：大型评测集如 MMLU-Pro 被划分为约 500MB 的多个分片，以支持并行评估逻辑 ()。
-
-

元数据映射：Parquet 文件中嵌入了字段的统计信息（如最小值、最大值和 NULL 计数），这使得像 DuckDB 这样的查询引擎能够实现谓词下推，快速筛选特定难度等级的样本 ()

-

评估协议与 API 交互标准

在分布式评估场景下，Agent 与评测服务器之间的通信遵循特定的协议规范。AgentBench 等基准提供了 Assigner 与 TaskWorker 的分离架构，允许评估框架实时监控 Agent 的运行消耗，并在检测到死循环或异常动作（如非法文件写入）时及时终止进程 。

组件名称	通信协议/数据格式	职责描述
Controller	HTTP/SSE (Server-Sent Events)	负责分发任务实例并维护评测状态机 。
TaskWorker	Docker API / JSON-RPC	实际运行沙盒环境，执行 Agent 指令并返回 Observation 。
Client	JSON 负载，包含 agent_id 和 action 。	Agent 发送行动请求的载体。

评测指标与结果汇总的数据模式

指标分类与计算标准
评测结果通常按任务类别、难度、模型参数规模等维度进行聚合。斯坦福 HELM 框架定义的 ExecutiveSummary 字段标准提供行业参考。

指标维度	字段定义	计算逻辑示例
准确性	mean_accuracy	所有实例中结果匹配的比例 。
校准度	calibration_error	模型输出概率与其真实预测准确率之间的差异 。
安全性	toxicity_score	生成文本中包含有害内容的实例百分比 。

指标维度	字段定义	计算逻辑示例
执行效率	pass_at_k	Agent 在 k 次尝试内成功完成任务的概率 。

LLM 基准类评测集数据格式标准

字段名称	数据类型	详细说明
id	字符串/整数	样本的唯一标识符，用于追踪特定题目在不同模型下的表现 。
subject	字符串	学科类别，如“astronomy”（天文学）或“clinical_medicine”（临床医学） 。
question	字符串	问题的文本主体，通常包含背景信息与提问核心 。
A, B, C, D	字符串	多项选择题的选项内容，部分扩展基准可支持多达 10 个选项 。
answer	字符串	正确选项的标签，如“A”、“B”等，作为评分的黄金标准 。
explanation	字符串	（可选）对正确答案的解释或推理逻辑，用于思维链（CoT）评测 。

推理与数学类基准的逻辑字段标准

字段名称	数据类型	详细说明
question	字符串	包含数学逻辑的问题描述，通常需要 2 到 8 个推理步骤 。
answer	字符串	包含完整推理步骤、计算注解及最终数值答案的文本 。
calculator_annotations	字符串	嵌入在答案中的特定标记，如 <<48/2=24>>，用于计算校验 。
final_answer_marker	字符串	预定义的定界符，如 ####，其后的内容为最终的数值结论 。

综合评估框架的数据流转标准

文件名称	核心字段描述	数据用途
run_spec.json	包含 scenario（场景）、adapter（适配器参数）、metrics（指标清单） 。	定义评测任务的元配置。
scenario.json	包含 instances（实例列表），每个实例包含 input 和 references 。	存储该运行对应的具体数据点。
scenario_state.json	记录每一次对模型的请求、响应以及生成过程中的概率分布 。	提供完整的生成溯源数据。
stats.json	各项指标在所有实例上的聚合统计值，如准确率、校准度等 。	输出最终的量化评估结果。

Agent 评测集数据格式标准

环境维度	数据字段标准	作用机制
instruction	任务指令（文本），如“查找系统中属于两个组以上的用户” 。	定义用户的意图与最终目标。
setup_script	用于初始化 Docker 镜像或沙盒环境的 Bash/Python 脚本 。	确保每个测试样本都在一致的初始状态下启动。
available_tools	包含工具名称、描述及 JSON Schema 格式的参数定义 。	限制 Agent 在该场景下可调用的行动空间。
verification_logic	用于验证环境状态变化的脚本或逻辑，而非简单的字符串匹配 。	判断 Agent 执行动作后是否达到了预期状态。

工具调用与函数签名数据标准

字段名称	必须/可选	详细定义标准
name	必须	唯一标识符，应采用描述性命名，如 SearchFlights 。

字段名称	必须/可选	详细定义标准
description	必须	向 LLM 解释工具的用途及调用时机，是工具选择的关键参考 。
parameters	必须	符合 JSON Schema 标准的对象，定义每个参数的类型、枚举值及描述 。
required	必须	列出所有必填参数的列表，确保 LLM 生成合规的调用请求 。
strict	可选	布尔值，开启后强制 LLM 严格遵循 Schema，不得生成额外属性 。

交互轨迹与执行日志的数据规范

轨迹层级	数据字段	内涵与功能
Root	schema_version, session_id, agent_metadata 。	定义轨迹文件的版本及所评估的 Agent 版本信息。
Step	step_id, timestamp, source (user/agent/system) 。	交互的时间序列记录，支持因果链条追溯。
Reasoning	reasoning_content 或思维链（CoT）文本 。	记录模型在行动前的内部思考过程，用于诊断逻辑错误。
Action	tool_calls (name, arguments) 。	模型发出的具体指令，通常为序列化的 JSON 格式。
Observation	observation_result (content, status_code) 。	环境返回的真实反馈，作为 Agent 下一轮决策的输入。
Metrics	step_tokens, cost_usd, latency_ms 。	衡量步骤效率及资源消耗的量化指标。

2.3、Case 数据集：收集/格式标准

OpenClaw：

openclaw-skill-ClawHub
https://clawhub.ai/

openclaw-case 汇总
https://github.com/hesamsheikh/awesome-openclaw-usecases

中文版本：高频场景
https://github.com/AlexAnys/awesome-openclaw-usecases-zh?tab=readme-ov-file#-%E4%B8%AD%E5%9B%BD%E7%89%B9%E8%89%B2%E7%94%A8%E4%BE%8B

行业	任务场景	任务概述	价值
	自主项目管理	多 Agent 协调，用 STATE.yaml 自动追踪项目状态	替代 Kanban 看板
	多渠道 AI 客服	WhatsApp + Instagram + 邮件 + Google 评价统一收件箱	一人撑起客服团队
	电话私人助理	通过语音电话和短信访问 AI Agent	不用打开电脑
	收件箱清理大师	自动总结订阅邮件，生成每日摘要	4,000+ 邮件两天清完
	个人 CRM	自动发现和追踪联系人信息	社交达人必备
	健康与症状追踪	记录饮食/症状，识别过敏源和触发因素	肠胃不好的救星
	多渠道私人助理	Telegram + Slack + 邮件 + 日历统一路由	一个入口管所有
	项目状态管理	事件驱动追踪，替代传统 Kanban 板	开发者的新选择
	动态仪表盘	实时并行数据抓取，自动生成面板	数据控的最爱
	Todoist 任务同步	将 AI 推理日志同步到 Todoist	让 AI 帮你管待办
	家庭日历助手	聚合全家人日历，管理库存清单	家庭主夫/主妇神器

行业	任务场景	任务概述	价值
	多 Agent 专业团队	通过 Telegram 协调多个专业 Agent	一人=一个团队
	定制晨报	个性化每日简报，通过短信推送	起床第一件事
	会议纪要自动化	转录→总结→生成待办→分配任务	告别手动记笔记
	习惯打卡教练	每日通过 Telegram/SMS 签到提醒	你的 AI 监工
	第二大脑	发条消息就能记住，配 Next.js 可搜索面板	记忆力外挂
	活动嘉宾确认	自动语音外呼收集 RSVP	办活动的刚需

三：可观测链路工具汇总（中间监测态）

3.1、Agent 全生命周期观测数据链路

暂时无法在飞书文档外展示此内容
Agent 的每一次执行都被建模为一个分布式的 Trace（追踪），
其内部由多个嵌套的 Spans（跨度）组成，用以表征从任务启动、意图识别到最终决策的每一个原子化步骤。

3.2、Agent 过程链路数据-标准格式（时序数据库存储）

第一阶段：Agent 运行时与链路追踪 (Runtime & Tracing)

Trace 表-核心存储字段

说明：Trace 主要记录了 Agent，一个会话可以对应多个 Trace。

-

这次请求的完整执行链是谁

-
-

一共跑了多少个步骤

-
-

调用了多少次模型、工具

-
-

总耗时多少

-
-

总成本多少

-
-

整体成功还是失败

-

中文字段名称	英文字段名称	字段说明	为什么存	示例	是否能获取	**指标提供**
Trace ID	trace_id	端到端调用链的唯一标识	关联整个调用	123e4567-e89b-12d3-a456-426614174000	是	业务埋点

			链、回溯问题			
Span ID	span_id	调用链中的单条操作标识	区分调用链中的不同操作	span_001	是	业务埋点
Span 类型	span_type	Span 的类型，如 agent、llm、workflow、tool、server	分析不同模块调用性能与瓶颈	llm / workflow / tool	是	业务埋点
开始时间	start_time	Span 操作开始时间	性能分析、调用序列	2026-01-28 21:41:52	是	业务埋点
结束时间	end_time	Span 操作结束时间	性能分	2026-01-28 21:43:06	是	业务埋点

			析、调用序列			
耗时	duration	单条Span操作耗时	性能分析、慢操作排查	48.71s	是	业务埋点
输入内容	input	Span的输入数据	调试、回溯请求内容	{"prompt":"生成图片"}	是	业务埋点
输出内容	output	Span的输出数据	调试、回溯结果	{"url":"https://..."}	是	业务埋点
模型名称	model_name	如果Span涉及模型调用，记录模型名称	成本分析、性能优化	openai/doubao-seed-1-6-250615	是	业务埋点
Token数	token_count	模型调用消耗Token	成本分	total 1081, input 265, output 816		业务埋点

			析			
调用工具/组件	invoked_tool	Span 中使用的工具或服务	调用链分析	execute_tool file_download	是	业务埋点
接口名	api_name	调用的接口或 Endpoint	链路追踪、问题定位	/run_sse		业务埋点
状态码	status_code	API 返回状态码	异常排查	200 / 500		Prometheus
错误数	error_count	单条 Span 中发生的错误数	异常分析	2		Prometheus
错误率	error_rate	单条 Span 的错误比例	SLO 监控	50%		Prometheus
请求比例	request_ratio	当前 Span 在整个 Trace 请求中占比	性能瓶颈分析	2 / 100%		Prometheus
传播比例	propagation_ratio	当前 Span 错误或延迟对上游/下游影响比例	问题溯源	100%		业务埋点

错误详情	error_detail	错误详细信息	异常排查、定位	"unknown"		业务埋点
调用次数	call_count	当前 Span 重复调用次数	性能分析、负载统计	4		Prometheus
屏蔽链路分支	filtered_branch	过滤掉的链路分支（可选）	数据精简、聚合分析	span_type != server		业务埋点

Span 明细表-核心存储字段

说明：Span 是整个可观测体系里最核心的一张表，表示 Trace 中的一个具体步骤。

中文字段名	英文字段名	字段说明	示例值	是否必填	为什么要存	是否能获取	指标提供
Span ID	span_id	当前步骤唯一标	span_004	是	唯一定位一个执行步骤	是	埋点

		识					
Trace ID	trace_id	所属调用链ID	trace_abc123	是	挂载到Trace上	是	埋点
父Span ID	parent_span_id	当前步骤的父步骤ID	span_002	否	构建树状调用关系	是	埋点
会话ID	session_id	所属会话ID	sess_20260316_001	否	支持从会话下钻到步骤	是	埋点
轮次ID	turn_id	所属轮次ID	turn_0003	否	精确定位会话中的某一步	是	埋点
Span名称	span_name	当前步骤展示名称	call_llm	是	前端列表展示核心字段		埋点
操作名称	operation_name	执行动作	call_llm	是	用于统一统计分析		埋点

		名称					
Span类型	span_type	当前步骤类型	llm / tool / http / workflow	是	类型筛选与聚合分析		埋点
组件类型	component_type	所属组件类别	agent / llm / tool / workflow	否	对应截图顶部标签体系		埋点
供应商/引擎	provider	具体供应商或执行引擎	openai	否	分析第三方依赖		埋点
Span层级	span_level	当前步骤在树中的深度层级	4	否	前端树形渲染、层级分析		埋点
排序序	sequence_no	在同级	7	否	回放顺序控制		埋点

号		中的顺序					
服务名称	service_name	执行该步骤的服务名	agent-gateway	否	看服务归属		埋点
服务版本	service_version	当前服务版本号	1.9.2	否	看版本影响		埋点
主机名	host_name	执行该步骤的机器/Pod	pod-agent-7f98	否	机器级排障		Prometheus
实例ID	instance_id	运行实例标识	ins_001	否	精准定位异常实例		Prometheus
开始时	start_time	Span开	2026-03-16T09:32:14.001Z	是	时序分析基础		埋点

间		始时间					
结束时间	end_time	Span结束时间	2026-03-16T09:32:14.682Z	否	时序分析基础		埋点
耗时(毫秒)	duration_ms	当前步骤耗时	681	否	性能瓶颈分析		trace
状态码	status_code	执行状态码	ok / error / timeout	是	判断步骤是否成功		Prometheus
状态说明	status_message	状态补充说明	timeout after 2s	否	便于前端展示与排障		埋点
是否异常	is_abnormal	当前步骤是否标记为异常	false	否	支持异常Span筛选		埋点
异	error_type	当	timeout / parse_error	否	错误归		埋点

常类型		前错误类型			因		
异常代码	error_code	当前错误码	HTTP_500	否	统一错误治理		埋点
重试次数	retry_count	当前步骤发生了几次重试	1	否	分析自愈能力		埋点
是否回退	is_fallback	是否触发降级/回退逻辑	false	否	分析容错设计效果		埋点
下游服务	downstream_service	当前步骤调用的下游	openai_api	否	分析依赖链		埋点

		服务					
请求方法	http_method	如果是HTTP调用，对应的方法	POST	否	对应接口调用分析		Prometheus
请求路径	http_path	如果是HTTP调用，对应路径	/v1/chat/completions	否	接口层性能与问题分析		Prometheus
工具名称	tool_name	若该Span是工具调用，对应工具名	duckdb_sql_execution	否	Tool分析关键字段		埋点

Agent名称	agent_name	若该Span属于Agent执行，对应Agent名	veAgent	否	Agent调用分层分析		埋点
工作流名称	workflow_name	若属于工作流，对应工作流名	data_analysis_workflow	否	Workflow 分析关键字段		埋点
输入内容引用	input_ref	输入原文或输入对象存储地址	obj://trace/inputs/span_004.json	否	避免大字段直接入库		埋点

输出内容引用	output_ref	输出原文或输出对象存储地址	obj://trace/outputs/span_004.json	否	支持回放与排障		埋点
脱敏后输入引用	masked_input_ref	脱敏后的输入存储地址	obj://masked/in_004.json	否	安全展示		埋点
脱敏后输出引用	masked_output_ref	脱敏后的输出存储地址	obj://masked/out_004.json	否	安全展示		埋点
是否包含PII	contains_pii	是否包含隐私数据	true	否	隐私合规		埋点

采集上报时间	reported_at	Trace系统接收到该Span的时间	2026-03-16T09:32:15.010Z	否	判断采集延迟		埋点
扩展属性	attributes	扩展字段JSON	{“cache_hit”:false}	否	预留灵活扩展能力		埋点

LLM 调用表-核心统计字段

中文字段名	英文字段名	字段说明	示例值	是否必填	为什么要存	指标提供
模型调用ID	inference_id	一次模型调用的唯一标识	inf_001	是	唯一定位一条模型请求	业务埋点

Trace ID	trace_id	所属Trace标识	trace_abc123	是	与链路关联	Tracing
Span ID	span_id	所属Span标识	span_003	是	与具体步骤关联	Tracing
会话ID	session_id	所属会话标识	sess_20260316_001	否	会话成本聚合	业务埋点
轮次ID	turn_id	所属轮次标识	turn_0003	否	定位某轮问题	业务埋点
Agent ID	agent_id	发起本次模型请求的Agent	refund_agent_v3	否	分析不同Agent的模型策略	业务埋点
模型供	provider	模型服	openai	是	对比不	业务埋点

应商		务提供商			同供应商效果	
模型名称	model_name	模型名称	gpt-4.1-mini	是	性能和成本分析的核心维度	埋点
模型版本	model_version	模型具体版本	2026-02-15	否	分析版本回归问题	埋点
调用接口类型	operation_name	使用的接口类型	chat_completion	是	区分不同调用模式	埋点
调用方式	request_mode	同步/流式/函数	stream	否	影响时延体验	埋点

		调用等				
系统提示词模板ID	system_prompt_template_id	系统提示词模板标识	tpl_sys_refund_v5	否	关联prompt模版治理	埋点
用户提示词模板ID	user_prompt_template_id	用户侧提示词模板标识	tpl_user_query_v2	否	看不同模版效果	埋点
提示词版本	prompt_version	当前使用的prompt版本	v5	否	做prompt A/B分析	埋点
系统提示词引用	system_prompt_ref	系统提示词对象存储	obj://prompts/system_001.txt	否	回放与调试	日志

		引用				
输入消息引用	input_messages_ref	输入消息列表引用	obj://prompts/messages_001.json	否	回放上下文	日志
输出内容引用	output_text_ref	模型输出内容引用	obj://outputs/inf_001.txt	否	质量检查与复盘	日志
输入上下文长度	context_length	本次输入上下文总长度	1820	否	分析长上下文影响	rate(vllm:prompt_tokens_total[1m])不精确
温度参数	temperature	采样温度	0.2	否	影响输出稳定性	埋点
Top P参数	top_p	采样top_p	1.0	否	影响生成	埋点

		参数			分布	
最大输出Token	max_tokens	允许输出的最大token数	1024	否	约束生成成本和长度	埋点
是否启用工具调用	tool_call_enabled	本次模型是否允许生成工具调用	true	否	判断Agent决策模式	Agent埋点
是否生成工具调用	tool_call_generated	本次模型是否真的生成了工具调用	true	否	看模型动作决策	Agent埋点

工具调用数量	tool_call_count	本次输出中生成的工具调用数	1	否	看单次调用复杂度	Agent 埋点
结束原因	finish_reason	模型输出结束原因	tool_calls / stop / length	否	判断模型停止路径	响应字段埋点
输入Token数	prompt_tokens	输入消耗token数	6439	是	成本分析核心字段	Prometheus
输出Token数	completion_tokens	输出消耗token数	164	是	成本分析核心字段	Prometheus
总Token	total_tokens	输入输	6603	否	规模统	Prometheus

数		出token总数			计	
缓存Token数	cached_tokens	命中缓存的token数	0	否	分析缓存收益	Prometheus
推理Token数	reasoning_tokens	深度思考/推理额外token	193	否	推理模型专项分析	Prometheus
首Token时延(毫秒)	first_token_latency_ms	从请求发出到首token返回的耗时	840	否	用户体感关键指标	Prometheus
总推理	end_to_end_latency_ms	整次模	2160	是	性能分	Prometheus

时延（毫秒）		型调用耗时			析核心字段	
排队耗时（毫秒）	queue_latency_ms	模型请求排队时间	40	否	判断平台排队问题	Prometheus
网络耗时（毫秒）	network_latency_ms	网络传输耗时	90	否	分析网络抖动	可计算但不精确
服务端处理耗时（毫秒）	server_latency_ms	模型服务端处理耗时	2030	否	细分性能瓶颈	可计算但不精确
输入成本（美元）	prompt_cost_usd	输入token费用	0.0058	否	成本拆分	计算
输出成本（美	completion_cost_usd	输出token费	0.0004	否	成本拆分	计算

元)		用				
推理总成本(美元)	total_cost_usd	本次模型调用总成本	0.0062	否	单次调用成本分析	计算
计费币种	currency	成本单位币种	USD	否	多币种支持	配置
是否成功	success	本次模型调用是否成功	true	是	便于成功率统计	Prometheus
状态码	status_code	模型调用返回状态码	200	否	排查接口错误	nginx-prometheus-exporter
错误类	error_type	错误分	rate_limit / timeout	否	模型错	日志/埋点

型		类			误治理	
错误信息	error_message	错误详细描述	request timeout	否	辅助排障	日志
安全拦截结果	safety_result	模型输出是否触发安全拦截	pass / blocked	否	安全治理	安全模块埋点
结构化输出标记	structured_output	是否输出为JSON/结构化格式	true	否	看模型结果可解析性	业务逻辑
结构化解析是否	structured_parse_success	结构化结果是否	true	否	看结构化输出稳	业务逻辑

成功		成功解析			定性	
模型标签	tags	模型调用业务标签	[“refund”,“tool_use”]	否	灵活筛选分析	配置/埋点

第二阶段：会话分析与用户上下文

会话分析

中文字段名称	英文字段名称	字段说明	为什么存	示例	**指标提供**
会话ID	conversation_id	唯一标识一次完整会话的 ID	用于追踪单次会话、查询历史、统计会话数	runtime_data_plane_st / 0dc3e9df-3dae-4060-b	埋点
用户ID	user_id	发起会话的用户标识	用户行为分	用户唯一 ID	埋点

			析、权限管理		
会话开始时间	start_time	会话开始时间	时间序列分析、问题排查	2025-12-11 15:03:XX	埋点
会话结束时间	end_time	会话结束时间	用于计算总耗时、历史回溯	2025-12-11 15:03:30	埋点
总耗时	duration	会话从开始到结束的总耗时	性能分析、慢会话排查	27.73s	埋点
会话状态	status	会话执行结果状态（成功/失败/超时）	用于统计成功率、问题排查	success / failed / timeout	埋点
总Token数	total_tokens	会话涉及的Token总数（输入+输出）	成本估算、资源规划	1205	埋点
输入Token数	input_tokens	会话输入内容消耗的Token数	用户请求复杂度分析	263	埋点

输出Token数	output_tokens	会话输出内容消耗的Token数	输出长度及成本分析	942	埋点
平均响应时间	avg_latency	会话中各调用链平均耗时	性能优化、延迟分析	5.2s	Prometheus
最大调用链耗时	max_chain_latency	会话中最耗时的调用链耗时	找出性能瓶颈	15.1s	埋点
调用链数	call_chain_count	会话中包含的工具/LLM调用链条数量	分析会话复杂度及多步骤操作	1	埋点
调用链ID	invocation_id	会话内部每条调用链唯一标识	追踪单次调用链性能	27条调用链中的某条ID	埋点
调用链开始时间	invocation_start_time	调用链开始时间	性能分析、链路延迟统计	2025-06-09 15:00:56	埋点
调用链结束时间	invocation_end_time	调用链结束时间	性能分析、链路延迟统计	2025-06-09 15:01:56	埋点

调用链耗时	invocation_duration	单条调用链耗时	用于性能分析、慢调用链排查	6.74s	埋点
调用链状态	invocation_status	单条调用链执行状态	性能问题和异常排查	success / failed / timeout	埋点
LLM模型名称	model_name	调用的模型名称	成本分析、版本控制、性能评估	doubao-1-5-lite-32k-250115	埋点
LLM消耗Token数	llm_token_count	单条调用链中LLM消耗的Token	成本分析、Token优化	721	埋点
输出内容	output	Agent最终返回的文本内容	结果校验、日志存档	市场经济是一种经济体制...	埋点
输出结构	output_json	JSON结构化输出，包括intent、solution_plan、tool_result、validation_result等	自动化分析、多维度评估会话	{"final_response":"...", "intent_analysis":"..."}	埋点

用户输入内容	input	用户请求的原始内容	回溯用户意图、训练分析	请用一句话解释市场经济	埋点
工具调用结果	tool_result	调用工具后的返回内容	验证工具是否正确执行	No tool matched / 知识库检索结果	埋点
验证结果	validation_result	验证 Agent 输出是否满足预期	提升 Agent 可靠性	工具执行步骤按预期返回结果	埋点
用户意图	intent	Agent 识别的用户意图	分析用户行为、意图分布	general / inquiry / command	埋点
执行计划	solution_plan	Agent 生成的执行步骤或方案	用于自动化流程优化、调试	直接调用知识库获取定义	埋点
错误码	error_code	会话或调用链中出现的错误码	异常排查、SLO 监控	500 / 404	埋点
异常信息	error_message	会话或调用链中出现的异常文本	异常排查	"No tool matched"	埋点
成本估算	estimated_cost	会话或调用链估算成本（可根据 Token/模型定价）	用于费用监控、	0.012 USD	埋点

			预算分析		
触发工具列表	triggered_tools	会话中调用过的所有工具列表	统计工具使用频率、优化策略	["knowledge_search", "calculator"]	埋点

第三阶段:RAG 与知识库检索

记忆库

中文字段名称	英文字段名称	字段说明	为什么存	示例	指标提供
记忆库名称	memory_db_name	记忆库的唯一标识或名称	用于区分不同记忆库实例、数据归属	mp-cn-memory / VikingDB	埋点

API总调用次数	api_call_count	对记忆库的总调用次数（包括创建事件、记忆召回等）	用于统计负载、调用频率、资源规划	15	Prometheus
平均延迟	avg_latency	记忆库调用平均耗时	性能分析、发现慢操作	0.47s	Prometheus
总错误率	error_rate	调用记忆库时的错误比例	异常排查、SLO监控	20%	Prometheus
创建事件调用	create_event_count	创建新记忆条目的API调用次数	用于监控写操	12	Prometheus

次数			作负载、写性能优化		
创建事件平均延迟	create_event_avg_latency	创建事件操作平均耗时	性能分析、慢写操作排查	0.38s	Prometheus
创建事件错误率	create_event_error_rate	创建事件操作错误率	异常分析、数据完整性监控	25%	Prometheus
记忆召回调用次数	recall_event_count	召回记忆条目的 API 调用次数	用于监控读操作负载	3	Prometheus

记忆召回平均延迟	recall_event_avg_latency	召回操作平均耗时	性能分析、读操作优化	0.81s	Prometheus
记忆召回错误率	recall_event_error_rate	召回操作错误率	异常分析、SLO监控	0%	Prometheus
Trace ID	trace_id	对应记忆库操作的链路追踪ID	用于调用链追踪、性能分析	123e4567-e89b-12d3-a456-426614174000	埋点
Span ID	span_id	单条操作的追踪ID	性能分析、慢操作排查	span_001	埋点

操作类型	operation_type	API 操作类型（创建/读取/更新/删除）	区分不同操作、监控读写负载	create / recall	埋点
输入内容	input	操作请求的输入内容	回溯操作意图、分析调用模式	{"key":"user_question","value":"Prometheus-agent 如何排查"}	埋点
输出内容	output	API 返回的记忆条目或结果	用于验证正确性、日志存档	{"result_list":[{"id":"doc-5027655","content":"…"}]}	埋点
模型名	model_name	如记忆库操作中涉及	成本分	text-embedding-3-small	埋点

称		模型推理或embedding生成时的模型	析、性能评估		
Token数	token_count	本次操作消耗的Token数（如涉及embedding生成）	成本监控、优化	128	埋点
操作开始时间	start_time	单条操作开始时间	追踪时间序列、性能分析	2025-12-12 15:05:15	埋点
操作结束时间	end_time	单条操作结束时间	追踪耗时、性能分析	2025-12-12 15:05:21	埋点
操作耗时	duration	单条操作耗时	性能优化、	216.95ms	埋点

			慢操作排查		
错误码	error_code	API 调用失败时返回的错误码	异常排查、数据完整性	500 / 404	埋点
异常信息	error_message	API 调用失败时的详细信息	异常排查、问题复现	"Memory key not found"	埋点
调用链详情	invocation_trace	关联 Trace/Span 的详细信息	调用链追踪、性能分析	trace_id + span_id 对应的调用链	埋点
调用工具/组件	invoked_tool	本次操作涉及的工具或组件	追踪操作路径	viking_knowledge / embedding_service	埋点

			、排查慢操作		

知识库检索表

中文字段名	英文字段名	字段说明	示例值	是否必填	为什么要存	指标提供
知识命中 ID	kb_hit_id	一次命中的唯一标识	hit_001	是	唯一定位某个命中文档块	埋点
RAG 检索 ID	rag_retrieval_id	所属 RAG 检索动作 ID	rag_001	是	与检索动作关联	埋点
Trace ID	trace_id	所属 Trace ID	trace_abc123	是	与链路关联	埋点
Span ID	span_id	所属 Span ID	span_005	否	与检索步骤对应	埋点
知识库 ID	knowledge_base_id	命中的知识库标识	kb_after_sales_v4	是	区分不同知识库	埋点
知识库名称	knowledge_base_name	知识库名	售后退款知识库	是	页面展示	埋点

		称			和汇报	
知识空间/命名空间	namespace	知识所属空间	after_sales	否	逻辑隔离	埋点
文档ID	document_id	命中的源文档ID	doc_11	是	追溯原始文档	埋点
文档标题	document_title	文档名称	退款到账时效规则	否	页面展示	埋点
文档版本	document_version	文档版本号	v12	否	分析版本问题	埋点
文档类型	document_type	文档类别	pdf / markdown / faq / policy	否	分析不同文档效果	埋点
chunk ID	chunk_id	命中的文本块ID	chunk_11_03	是	精确定位文档块	埋点
chunk序号	chunk_index	文档内块序号	3	否	回溯原文位置	埋点
chunk内容引用	chunk_content_ref	命中chunk的内容引用	obj://kb/chunk_11_03.txt	否	不把大文本直接入库	埋点
chunk摘要	chunk_summary	命中内容摘要	审核通过后1-3个工作日到账	否	快速查看	埋点
chunk长度	chunk_chars	chunk字符	286	否	分析chun	Prometheus

(字符)		长度			k 粒度	
chunk 长度 (Token)	chunk_tokens	chunk token 数	121	否	上下文拼装分析	Prometheus
chunk 召回分数	recall_score	初始召回分数	0.91	否	判断召回强弱	埋点
chunk 重排分数	rerank_score	rerank 后分数	0.97	否	判断重排效果	埋点
排名位置	rank_position	最终排序位置	1	否	看结果排序质量	埋点
匹配方式	match_type	通过什么方式命中	vector / keyword / rule	否	分析命中来源	埋点
是否最终入模	selected_for_context	是否被选入最终上下文	true	否	区分“召回”与“真正使用”	埋点
是否在回答中被引用	cited_in_answer	最终回答是否引用了该知识	true	否	判断知识利用率	埋点
引用位置	citation_position	若被引用，在回答中	[1]	否	支持溯源展示	埋点

		的位置				
文档更新时间	document_updated_at	原文档最后更新时间	2026-03-10T12:00:00Z	否	看知识是否新鲜	埋点
文档生效时间	effective_at	文档规则生效时间	2026-03-01T00:00:00Z	否	适合政策类知识	埋点
文档失效时间	expired_at	文档规则失效时间	null	否	防止引用过期知识	埋点
权限级别	permission_level	文档权限等级	public / internal / restricted	否	权限治理	埋点
权限过滤标记	permission_filtered	是否经过权限过滤	true	否	保证知识合规	埋点
知识可信度标签	knowledge_quality_label	对知识质量的人工/自动标记	trusted / outdated / low_confidence	否	知识治理	埋点
是否过期知识	is_outdated	命中内容是否过期	false	否	避免旧知识误导	埋点
是否冲突知识	is_conflicted	是否与其他知识冲突	false	否	识别知识库一致性问题	埋点

业务标签	business_tags	文档业务标签	[“refund”,“policy”]	否	多维分类	埋点

第四阶段:工具调用与动作追踪

工具调用表（Tool Call）

中文字段名	英文字段名	字段说明	示例值	是否必填	为什么要存	指标提供
工具调用ID	tool_call_id	一次工具调用的唯一标识	tool_001	是	唯一定位一次工具执行	埋点
Trace ID	trace_id	所属调用链ID	trace_abc123	是	与Trace关联	埋点
Span ID	span_id	所属Span ID	span_004	是	与具体步骤关联	埋点
父Span ID	parent_span_id	发起该工具调用的父步骤ID	span_003	否	还原是谁触发了工具	埋点

会话ID	session_id	所属会话ID	sess_20260316_001	否	做会话级分析	埋点
轮次ID	turn_id	所属轮次ID	turn_0003	否	做某轮追踪	埋点
Agent ID	agent_id	发起调用的Agent	data_agent_v2	否	分析不同Agent的工具使用差异	埋点
工具名称	tool_name	工具名称	duckdb_sql_execution	是	核心识别字段	埋点
工具中文名	tool_display_name	工具展示名	DuckDB SQL执行工具	否	便于页面展示和汇报	埋点
工具类别	tool_category	工具所属类别	sql_execution / search / api / plugin	是	支持分类分析	埋点
工具版本	tool_version	工具版本号	2.1.0	否	做版本问题定位	埋点
工具提供方	tool_provider	工具归属方	internal / third_party	否	区分自研与外部依赖	埋点
调用方式	invoke_type	同步/异步/流式	sync	否	分析执行模式	埋点

		/批处理				
接口协议	protocol	工具调用协议	http / grpc / local / sdk	否	分析接入方式	埋点
请求方法	http_method	若为HTTP调用，请求方法	POST	否	接口分析	埋点
请求地址	endpoint	工具调用的接口地址	/api/query/sql	否	故障排查	埋点
请求参数引用	request_args_ref	工具请求参数存储地址	obj://tool_args/tool_001.json	否	大字段不直接入库	埋点
脱敏后请求参数引用	masked_request_args_ref	脱敏后的请求参数地址	obj://masked/tool_001_args.json	否	安全展示	埋点
请求参数摘要	request_args_summary	请求参数摘要	查询销售明细表近 7 天数据	否	页面快速查看	埋点
请求Schema版本	request_schema_version	请求参数结构版本	v3	否	避免版本兼容问题	埋点
响应结果引用	response_ref	工具响应结果存储	obj://tool_resp/tool_001.json	否	回放与问题定位	埋点

		地址				
脱敏后响应引用	masked_response_ref	脱敏响应地址	obj://masked/tool_001_resp.json	否	安全展示	埋点
响应摘要	response_summary	工具返回摘要	返回 132 行结果数据	否	页面快速查看	埋点
响应Schema版本	response_schema_version	响应结构版本	v2	否	兼容不同工具输出格式	埋点
是否成功	success	工具调用是否成功	true	是	成功率统计核心字段	埋点
平台状态码	status_code	平台级状态码	ok / error / timeout	是	统一状态分析	埋点
HTTP状态码	http_status_code	HTTP返回码	200	否	接口异常定位	Prometheus
业务状态码	business_status_code	业务层状态码	OK / EMPTY_RESULT	否	判断是系统错还是业务空结果	埋点
错误类型	error_type	错误分类	timeout / auth_error / parse_error	否	错误治理	埋点
错误信息	error_message	错误详细	tool response parse failed	否	排障	埋点

		信息				
开始时间	started_at	工具调用开始时间	2026-03-16T09:32:14.001Z	是	时序分析	埋点
结束时间	ended_at	工具调用结束时间	2026-03-16T09:32:14.682Z	否	时序分析	埋点
调用耗时(毫秒)	latency_ms	工具调用总耗时	681	是	性能分析核心字段	埋点
排队耗时(毫秒)	queue_latency_ms	工具在队列中等待耗时	20	否	分析工具排队问题	埋点
网络耗时(毫秒)	network_latency_ms	网络传输耗时	60	否	分析网络瓶颈	埋点
服务端处理耗时(毫秒)	server_latency_ms	下游工具服务处理耗时	550	否	识别工具内部慢点	埋点
重试次数	retry_count	工具请求重试次数	1	否	分析可靠性	埋点
是否触发降级	is_fallback	是否触发降级逻辑	false	否	分析容错策略	埋点

降级方式	fallback_strategy	使用的降级方式	cache / mock / alternative_tool	否	分析恢复路径	埋点
是否熔断	circuit_breaker_open	是否触发熔断	false	否	稳定性治理	埋点
是否命中缓存	cache_hit	是否命中缓存	false	否	分析性能优化效果	埋点
请求大小(字节)	request_size_bytes	请求体大小	512	否	网络和存储开销分析	埋点
响应大小(字节)	response_size_bytes	响应体大小	2481	否	网络和存储开销分析	埋点
返回结果条数	result_count	工具返回结果数量	132	否	判断是否空结果或过大结果	埋点
工具调用成本(¥)	tool_cost_usd	本次工具调用成本	0.0008	否	完整成本账本	埋点
标签	tags	业务标签	[“sql”,“analytics”]	否	灵活筛选	埋点
扩展属性	attributes	扩展JSON属性	{“db”:“sales_dw”}	否	留扩展空间	埋点

第五阶段:输出结果与推理评价

模型监控

中文字段	英文字段	字段说明	数据类型	示例值	备注
模型名称	model_name	被监控模型的名称	string	doubao-1-5-lite-32k-250115	下拉可选
模型调用总次数	call_total	模型在监控时间范围内的调用总次数	integer	120	可用于压力分析
模型调用平均耗时	avg_duration	模型调用的平均耗时	float (秒)	3.29	性能分析指标
模型调用错误次数	error_count	模型调用的错误次数	integer	0	SLA或异常监控
Token使用总量	token_total	模型在监控时间范围内消耗的	integer	19126	成本分析

		Token 总量			
模型调用次数图	call_times_chart	模型调用次数的时间序列图	json/array	[时间点, 次数]	用于绘制折线或柱状图
模型平均耗时图	avg_duration_chart	模型调用平均耗时随时间变化图	json/array	[时间点, 平均耗时]	用于性能趋势分析
Token 使用量图	token_usage_chart	模型 Token 消耗量随时间变化图	json/array	[时间点, Token 数]	成本趋势分析
模型调用 Runtime 排行 Top5	runtime_top5	各 Runtime 的调用次数排名	json/array	[{service: "xxx", value: 120}]	性能归因
模型调用平均耗时 Runtime 排行 Top5	avg_runtime_top5	各 Runtime 平均耗时排行	json/array	[{service: "xxx", value: 3.29}]	性能归因
模型调	error_runtime_top5	各	json/arra	[{service: "xxx", value:	SL

用错误Runtime排行Top5		Runtime调用错误排行	y	0}]	A分析
Token使用Runtime排行Top5	token_runtime_top5	各Runtime的Token消耗排行	json/array	[{service: "xxx", value: 19126}]	成本归因
模型请求耗时分位数	request_percentiles	模型请求耗时的分位数	json/array	[p50: 2.5s, p90: 3.8s]	性能分析
TTFT分位数	ttft_percentile	模型首次响应时间（Time To First Token）分位数	json/array	[p50: 500ms, p90: 1.2s]	性能分析
TPOT分位数	tpot_percentile	模型单次处理时间（Time Per Output Token）分位数	json/array	[p50: 20ms, p90: 45ms]	性能分析

第六阶段：服务性能与成本核算

芯片推理性能表

中文字段名	英文字段名	字段说明	示例值	是否必填	为什么要存	指标提供
推理性能记录ID	inference_perf_id	一次推理性能记录唯一标识	perf_001	是	唯一定位一条性能记录	埋点
Trace ID	trace_id	所属Trace ID	trace_abc123	是	与链路关联	埋点
Span ID	span_id	所属LLM Span ID	span_003	是	与模型调用关联	埋点
模型调用ID	inference_id	对应的LLM 调用 ID	inf_001	是	与 LLM 调用表打通	埋点
会话ID	session_id	所属会话 ID	sess_20260316_001	否	会话级成本汇总	埋点
Agent ID	agent_id	发起推理的Agent	data_agent_v2	否	分析不同Agent模式的推理差异	埋点
场景编码	scenario_code	所属业务场景	data_analysis	否	做场景级性能对比	埋点
模型供应商	provider	模型服务提供商	openai / local / vllm	是	区分推理来源	埋点
模型名称	model_name	模型名称	qwen2.5-72b	是	性能分析核心维度	埋点

模型版本	model_version	模型版本号	2026-03	否	版本对比	埋点
推理框架	inference_engine	推理引擎	vllm / sglang / tensorrt_llm	否	分析不同引擎表现	埋点
部署方式	deployment_mode	云 API / 本地部署 / 集群推理	cluster_local	否	影响成本结构	埋点
芯片厂商	chip_vendor	芯片提供方	NVIDIA / 昇腾 / 寒武纪	是	芯片选型分析	埋点
芯片型号	chip_model	具体芯片型号	A800 / 910B / 4090	是	核心对比维度	埋点
芯片规格	chip_spec	芯片规格说明	80GB HBM	否	细化硬件能力	埋点
节点ID	node_id	推理节点标识	node_gpu_07	否	节点级排障	埋点
集群名称	cluster_name	所在集群	agent_perf_cluster	否	集群级治理	埋点
容器/实例ID	instance_id	推理实例标识	pod-llm-001	否	实例定位	Prometheus
并发数	concurrency	当时并发请求数	8	否	解释性能变化	Prometheus
批大小	batch_size	推理批次大小	4	否	分析吞吐优化	埋点
输入Token数	prompt_tokens	输入token数	6439	是	成本和吞吐核心指标	埋点
输出Token数	completion_tokens	输出token数	164	是	成本和吞吐核心指标	埋点

总Token数	total_tokens	输入输出token总和	6603	是	总体规模分析	埋点
缓存Token数	cached_tokens	命中KV cache的token数	1200	否	评估缓存收益	埋点
预填充Token数	prefill_tokens	Prefill 阶段token数	6439	否	分析prefill 开销	埋点
解码Token数	decode_tokens	Decode阶段输出token数	164	否	分析decode效率	埋点
首Token时延(毫秒)	first_token_latency_ms	从请求到首token输出耗时	840	是	用户体验核心指标	Prometheus
总推理耗时(毫秒)	total_latency_ms	整次推理总耗时	2160	是	性能核心指标	Prometheus
预填充耗时(毫秒)	prefill_latency_ms	Prefill 阶段耗时	980	否	分析长上下文问题	埋点
解码耗时(毫	decode_latency_ms	Decode阶段耗时	1180	否	分析输出速度	埋点

秒)						
平均每秒输出Token	output_tps	输出吞吐，tokens per second	138.9	否	衡量生成效率	Prometheus
平均每秒-总Token吞吐	total_tps	总token吞吐	3056.0	否	看整体处理效率	Prometheus
单卡吞吐	per_chip_tps	单芯片token吞吐	76.5	否	芯片对比必备	埋点
首包时延	first_packet_latency_ms	流式首包返回时间	780	否	前端体感分析	Prometheus
请求排队耗时(毫秒)	queue_latency_ms	推理前排队时间	40	否	平台拥塞分析	埋点
框架调度耗时(毫秒)	scheduler_latency_ms	推理框架调度耗时	25	否	引擎优化分析	埋点
GPU利用率(%)	gpu_utilization	GPU 使用率	78.5	否	分析资源利用	Prometheus
NPU利用率(%)	npu_utilization	NPU 使用率	72.1	否	非GPU芯片分析	Prometheus

显存占用(MB)	gpu_memory_mb	显存使用量	56320	否	显存瓶颈分析	Prometheus
高带宽内存占用(MB)	hbm_memory_mb	HBM 使用量	61440	否	芯片级资源分析	Prometheus
CPU 利用率(%)	cpu_utilization	CPU 使用率	36.2	否	看调度和后处理消耗	Prometheus
主机内存占用(MB)	host_memory_mb	主机内存使用	12800	否	分析系统级开销	Prometheus
功耗(瓦)	power_watts	芯片功耗	285	否	能效分析	Prometheus
温度(℃)	temperature_celsius	芯片温度	71	否	稳定性分析	Prometheus
KV Cache 命中率	kv_cache_hit_rate	KV cache 命中比例	0.83	否	长会话优化关键指标	埋点
上下文窗口利用率	context_window_usage_rate	输入上下文占窗口比例	0.63	否	分析上下文冗余	埋点

Token 成本

中文字段名	英文字段名	字段说明	示例值	是否必填	为什么要存	指标提供

单次推理成本(美元)	total_cost_usd	本次推理总成本	0.0062	否	成本分析核心指标	埋点
输入成本(美元)	prompt_cost_usd	输入token对应成本	0.0058	否	成本拆分	埋点
输出成本(美元)	completion_cost_usd	输出token对应成本	0.0004	否	成本拆分	埋点
芯片算力成本(美元)	chip_compute_cost_usd	芯片算力分摊成本	0.0021	否	芯片投入产出分析	埋点
显存成本(美元)	memory_cost_usd	显存资源分摊成本	0.0006	否	资源细分核算	埋点
网络成本(美元)	network_cost_usd	推理相关网络成本	0.0001	否	完整成本视角	埋点
单千Token	cost_per_1k_tokens	每千token	0.94	否	统一	埋点

成本(美元)		成本			横向比较	
单次请求成本效率	cost_efficiency_score	性能/成本综合得分	0.81	否	做芯片和模型对比	埋点
是否成功	success	本次推理是否成功	true	是	成功率分析	埋点
错误类型	error_type	失败类型	oom / timeout / engine_error	否	排障与优化	埋点
错误信息	error_message	错误说明	cuda out of memory	否	具体排障	埋点
采样时间	sampled_at	性能指标采样时间	2026-03-16T09:32:15Z	否	与监控系统对齐	埋点

3.3、观测汇集工具汇总

调研工具：Langfuse、k6、普罗米修斯、playwright、granfa、EvalScope

1、Agent 全链路观测工具-Langfuse

可观测链路开源工具直接集成到 Aaas 验证平台中：核心定位

-

质量与成本关联：关联推理延迟、Token 成本、性能评分等指标。

-
-

根因下钻：当发现成本飙升或质量下降时，可下钻至具体某次推理的完整日志和链路，定位低效步骤，例如：模型性能指标、推理性能的下降、高并发导致的异常问题等。

-

具体可参考：Agent 推理链路可观测方案与计划

2、Agent 压测框架-EvalScope

模型评测与性能基准测试框架：简介 | EvalScope

-

基准数据集：预置了多个常用测试基准，包括：MMLU、CMMLU、C-Eval、GSM8K、ARC、HellaSwag、TruthfulQA、MATH、HumanEval 等。

-
-

评测指标：实现了多种常用评测指标。

-
-

模型接入：统一的模型接入机制，兼容多个系列模型的 Generate、Chat 接口。

-
-

自动评测：包括客观题自动评测和使用专家模型进行的复杂任务评测。

-
-

评测报告：自动生成评测报告。

-
-

竞技场(Arena)模式：用于模型间的比较以及模型的客观评测，支持多种评测模式，包括：

-
    -

  Single mode：对单个模型进行评分。

    -
    -

  Pairwise-baseline mode：与基线模型进行对比。

    -
    -

  Pairwise (all) mode：所有模型间的两两对比。

    -

-

可视化工具：提供直观的评测结果展示。

-
-

模型性能评测：提供模型推理服务压测工具和详细统计，详见模型性能评测文档。

-
-

OpenCompass 集成：支持 OpenCompass 作为评测后端，对其进行了高级封装和任务简化，您可以更轻松地提交任务进行评测。

-

-

VLMEvalKit 集成：支持 VLMEvalKit 作为评测后端，轻松发起多模态评测任务，支持多种多模态模型和数据集。

-

包括以下模块：

1.

输入层

2.

-

模型来源：API 模型（OpenAI API）、本地模型（ModelScope）

-
-

数据集：标准评测基准（MMLU/GSM8k 等）、自定义数据（MCQ/QA）

-

1.

核心功能

2.

-

多后端评估

-

    -

原生后端：LLM/VLM/Embedding/T2I 模型统一评估

    -
    -

集成框架：OpenCompass/MTEB/VLMEvalKit/RAGAS

-

-

性能监控

-

-

模型插件：支持多种模型服务 API

-
-

数据插件：支持多种数据格式

-
-

指标追踪：TTFT/TPOP/稳定性 等指标

-

-

工具扩展

-

-

集成：Tool-Bench/Needle-in-a-Haystack/BFCL-v3

-

1.

输出层

2.

-

结构化报告：支持 JSON/Table/Logs

-
-

可视化平台：支持 Gradio/Wandb/SwanLab

-

3、负载测试工具-K6

K6 是一个现代化的、开源的负载测试框架，可以帮助开发者和测试人员对 Web 应用程序、API 以及微服务进行性能测试。

三： 推理效率与性能验证指标（输出）

定位：这里汇总两大数据指标：推理过程中 Maas 和 Agent 可观测链路的多个数据源，汇总后统一统计

说明：以下指标均建立在 Agent 在特定场景下的特定任务所输出的关联性时序结果

3.1、 Agent 任务推理指标

端到端核心输出指标

指标	英文名称	解释
首次生成 token 时间	TTFT (Time to First Token)	从发送请求到生成第一个 token 的时间（以秒为单位），评估首包延时
输出 token 间时延	ITL (Inter-token Latency)	生成每个输出 token 间隔时间（以秒为单位），评估输出是否平稳

指标	英文名称	解释
每 token 延迟	TPOT (Time per Output Token)	生成每个输出 token 所需的时间（不包含首 token，以秒为单位），评估解码速度
端到端延迟时间	Latency	从发送请求到接收完整响应的时间（以秒为单位）：TTFT + TPOT * Output tokens
输入 token 数	Input tokens	请求中输入的 token 数量
输出 token 数	Output tokens	响应中生成的 token 数量
输出吞吐量	Output Throughput	每秒输出的 token 数量：输出 tokens / 端到端延时
总吞吐量	Total throughput	每秒处理的 token 数量：(输入 tokens + 输出 tokens) / 端到端延时

Agent-推理过程指标

监控层级	观测项	含义	示例
内部接口	路径	请求的路径。	/v1/completions
	状态码	请求的处理状态。	200/400
	客户端	客户端的类别。	Chrome/HTTP Client
	耗时	请求的处理时间。	1 s
模型输入/	提示词	用户对模型的输入。	深圳改革开放历史?
	响应方式	是否以流的方式发送生成的 Token。	Stream/None Stream

监控层级	观测项	含义	示例
输出	模型名称	被使用的 LLM 名称。	Qwen/Qwen2.5-0.5B
	最大 Token 数	模型生成的 Token 数量的上限，数量越大生成的时间越长。	1000
	温度 (Temperature)	控制生成文本随机性和多样性的关键参数。温度越低，模型倾向于选择最高概率词，输出确定性高；温度越高，低概率词被选中几率增加，输出创意性强但可能不连贯。	0 / 0.5 / 0.9
	Top-K	模型在生成每个词时，仅保留概率最高的前 K 个候选词，并从中间随机采样。	3 / 5
	Top-P 非首 token 延迟	根据概率累积阈值 P 动态选择候选词。例如当 P=0.9 时，模型会按概率从高到低累加，直到总和≥0.9，仅保留这部分词进行随机采样。	0.5 / 0.9
	N	指定从生成的文本中返回的建议答案数量。	1 / 3
推理过程	E2E 时间 E2EL (End-to-End Request Latency)	**端到端任务延时** 推理总时间，从接受到请求开始计算，直到推理完成。	1 s
	首 Token 时间	从向模型输入 Prompt 开始到模型生成第一个输出 token 所花费的时间。反映模型的初始响应速度，对于实时交互式应用非常重要，较低的 TTFT 可以提高用户体验，使用户感觉模型响应迅速，约等于等待时间 + Prefill 时间。	1 s

监控层级	观测项	含义	示例
	Prefill 时间	Prefill 阶段所耗费的时间。	1 s
	Decode 时间	Decode 阶段所耗费的时间。	1 s
	等待时间	请求在调度器中等待的时间。	1 s
	Token 间隔时间	模型在输出阶段（Decode 阶段）每个输出 token 的延时，衡量模型的生成速度。	1 s
	字间抖动（Inter-Token Latency Jitter）	该指标反映了生成过程中字与字之间停顿的一致性。对于语音智能体或实时交互智能体，高抖动会导致语流断续，极大地损害用户体验 。工程上，这通常与批处理（Batching）调度策略、资源竞争以及硬件调度器的确定性有关 。	
推理引擎状态	运行中请求数	正在推理的请求数量。	2
	等待请求数	等待被调度去执行的请求数量。	2
	被抢占请求数	当 KV Cache 不足时，请求被调度出 GPU，释放对应 GPU 内存，以便为其它请求腾出 KV Cache 空间。	5
	KV Cache 使用率	KV Cache 使用率，较高的使用率可能导致性能下降。	90%
	总提示词 Token 数量	所有请求的提示词的 Token 总数。	1000
	总生成 Token 数量	所有请求生成的 Token 总数。	1000

监控层级	观测项	含义	示例
	处理成功的请求数	已被成功处理的总请求数。	1000
治理策略执行追踪	限流统计	记录被限流的请求数量，分析限流触发原因（如某消费者突增流量）。	
	缓存命中情况	展示缓存命中与未命中的请求数，评估缓存策略有效性。	
	Fallback 执行路径	当主模型不可用时，记录请求是否成功降级至备用模型（如从 DeepSeek APIfallback 到自建 Qwen），并统计 fallback 成功率。	

Agent-模型观测指标

指标名称	单位	说明
模型调用总次数		调用指定模型的总次数。
模型调用平均耗时	s	调用指定模型的平均耗时。
模型调用错误次数		调用指定模型失败的次数。
Token 使用总量		指定模型 Token 消耗总量（input + output）。
LLM 单次调用消耗 Token		当前应用每次调用 LLM 的 Token 用量。
Token 使用模型排行（Top5）		当前应用调用所有 LLM 的 Token 使用总量排名前 5 的模型列表。
Token 使用总量-趋势类		当前应用调用所有 LLM 的 Token 使用总量趋势。

指标名称	单位	说明
LLM 单次调用消耗 Token-趋势类		当前应用每次调用 LLM 的消耗 Token 用量趋势。
模型调用次数-趋势类		调用指定模型的次数趋势。
模型调用平均耗时-趋势类	s	调用指定模型的平均耗时趋势。
模型调用错误-趋势类		调用指定模型失败的次数趋势。
Token 使用量-趋势类		指定模型 Token 消耗总量（input + output）趋势。
模型调用 Runtime 排行（TOP5）		调用指定模型次数排名前 5 的运行时列表。
模型调用平均耗时 Runtime 排行（TOP5）		调用指定模型平均耗时排名前 5 的运行时列表。
模型调用错误 Runtime 排行（TOP5）		调用指定模型错误次数排名前 5 的运行时列表。
Token 使用 Runtime 排行（TOP5）		调用指定模型消耗 Token 排名前 5 的运行时列表。
模型请求耗时分位数	s	调用指定模型耗时分位数 P99/P90/P75/P50。
TTFT 分位数	s	调用指定模型返回首包数据的平均耗时分位数 P99/P90/P75/P50。
TPOT 分位数	ms	调用模型在首个 Token 输出后，后续输出每个 Token 所需的时间分位数。

3.2、 Agent 任务全链路监测指标

Agent -运行时相关观测指标

类别	指标名称	单位	说明
智能体运行时	请求次数	Count	展示当前采集周期内（例如 1 小时），智能体运行时接口接收的总请求量。
	请求分布（范围/精确）	Count	展示当前采集周期内（例如 1 小时），从请求分布的范围和精确两个维度监控智能体运行时监控指标。 • 请求分布（范围）：以宏观区间或范围为维度统计请求分布。 • • 请求分布（精确）：以具体对象或值为维度统计请求分布。 •
	平均延迟	ms	展示当前采集周期内（例如 1 小时），智能体运行时处理请求的平均耗时。
	出向响应带宽	bit/s	展示当前采集周期内（例如 1 小时），每秒流出智能体运行时的流量。
	会话数	轮	指定时间段内存在调用的会话总数。提供监控看板，方便查看数据趋势。
	Token 消耗数	M	指定时间段内调用大模型消耗的 Token 总数，包含输入和输出 Token 数量。
智能体实例资源	CPU使用率	%	展示当前采样周期内（例如 1 小时），智能体运行时的 CPU 使用率。 说明 该 CPU 使用率为目标智能体运行时所有实例的 CPU 使用率平均值。
	CPU 耗时	min	当前 Runtime 实例在指定时间段内某个时刻消耗的 CPU 时间，包括：用户态 CPU 耗时和内核态 CPU 耗时。CPU 耗时可直观反映当前运行时的执行效率。

类别	指标名称	单位	说明
	内存	%	展示当前采样周期内（例如 1 小时），智能体运行时的内存使用率。 说明 • 该内存使用率为目标智能体运行时所有实例的内存使用率平均值。 • • 内存使用率 = 所消耗的实际内存/允许消耗的内存上限。 •
	线程数量	——	当前 Runtime 实例在指定时间段内某个时刻的线程数量，线程数量趋势可用于发现线程资源瓶颈、优化线程并发度。
	实例数量	Count	展示当前采样周期内（例如 1 小时），智能体运行时运行中的实例数量。

Agent -调用工具相关观测指标

类型	指标名称	单位	说明
工具	请求次数	Count	展示当前采样周期内（例如 1 小时），工具接口接收的总请求量。
	请求分布（范围/精确）	Count	展示当前采样周期内（例如 1 小时），从请求分布的范围和精确两个维度监控工具监控指标。 • 请求分布（范围）：以宏观区间或范围为维度统计请求分布。

类型	指标名称	单位	说明
			• • 请求分布（精确）：以具体对象或值为维度统计请求分布。 •
	平均延迟	ms	展示当前采样周期内（例如 1 小时），工具处理请求的平均耗时。
	出向响应带宽	bit/s	展示当前采样周期内（例如 1 小时），每秒流出工具的流量。
	工具数量	个	指定时间段内查询到的工具总数。提供工具列表，可查看工具清单和工具相关基础信息。
	调用数	个	指定时间段内所有工具的调用数量。提供调用数趋势图，方便了解不同时间段内工具的使用频率，合理规划资源。
	错误数	次	指定时间段内工具调用失败的数量。
	错误率	%	指定时间段内工具调用失败的错误率，错误率 = 错误数 / 调用数。提供错误率趋势图，方便检测系统稳定性，保障用户体验。
工具实例资源	CPU	%	展示当前采样周期内（例如 1 小时），工具的 CPU 使用率。 说明 该 CPU 使用率为目标工具所有实例的 CPU 使用率平均值。
	内存	%	展示当前采样周期内（例如 1 小时），工具的内存使用率。 说明 • 该内存使用率为目标工具所有实例的内存使

类型	指标名称	单位	说明
			用率平均值。 • • 内存使用率 = 所消耗的实际内存/允许消耗的内存上限。 •
	实例数量	Count	展示当前采样周期内（例如 1 小时），工具运行中的实例数量。

Agent -记忆库相关观测指标

类别	指标	单位	说明
创建事件	API 调用次数	Count	在指定统计周期内（例如 1 小时、1 天等）记忆库**添加会话、添加事件、添加画像**等接口接收的总请求量。
	平均延迟	ms/s	在指定统计周期内（例如 1 小时、1 天等）记忆库**添加记忆**请求的平均响应时间。
	总错误率	%	在指定统计周期内（例如 1 小时、1 天等）记忆库**添加记忆**时发生错误的比例，总错误率 错误操作数 / 总操作次数。
记忆召回	API 调用次数	Count	在指定统计周期内（例如 1 小时、1 天等）记忆库**检索接口**的总请求量。
	平均延迟	ms	在指定统计周期内（例如 1 小时、1 天等）记忆库**检索接口**请求的平均响应时间。
	总错误率	%	在指定统计周期内（例如 1 小时、1 天等）记忆库**检索接口**发生错误的比例，总错误率 错误操作数 / 总操作次数。

Agent -MCP 服务相关观测指标

分类	指标名称	单位	说明
服务调用	请求次数	Count	在指定统计周期内（例如 1 小时）MCP 服务接口接收的总请求量。
	请求分布（范围/精确）	Count	在指定统计周期内（例如 1 小时），从请求分布的范围和精确两个维度监控 MCP 服务监控指标。 • 请求分布（范围）：以宏观区间或范围为维度统计请求分布。 • • 请求分布（精确）：以具体对象或值为维度统计请求分布。 •
	平均延迟	ms	在指定统计周期（例如 1 小时）内，MCP 服务处理请求的平均耗时。
服务运行	CPU 使用率	%	展示当前采样周期（例如 1 小时）内，MCP 服务的 CPU 使用率。 说明 该 CPU 使用率为目标 MCP 服务下，所有实例的 CPU 使用率平均值。
	内存使用率	%	展示当前采样周期（例如 1 小时）内，MCP 服务的内存使用率。 说明 • 该内存使用率为目标 MCP 服务下，所有实例的内存使用率平均值。 • • 内存使用率 = 所消耗的实际内存/允许消

分类	指标名称	单位	说明
			耗的内存上限。 •
	实例数量	Count	展示当前采样周期（例如 1 小时）内，目标 MCP 服务下运行中的实例数量。

3.3、 Agent 任务-性能指标

性能-综合压测指标-EvalScope

指标	英文名称	解释	公式
测试总时长	Time taken for tests	整个测试过程从开始到结束所花费的总时间	最后一个请求结束时间 - 第一个请求开始时间
并发数	Number of concurrency	同时发送请求的客户端数量	预设值
总请求数	Total requests	在整个测试过程中发送的所有请求的数量	成功请求数 + 失败请求数
成功请求数	Succeed requests	成功完成并返回预期结果的请求数量	直接统计
失败请求数	Failed requests	由于各种原因未能成功完成的请求数量	直接统计
输出吞吐量	Output token throughput	每秒钟处理的平均标记（token）数	总输出 token 数 / 测试总时长
总吞吐量	Total token throughput	每秒钟处理的平均标记（token）数	总输入 token 数 + 总输出 token 数 / 测试总时长
请求吞吐量	Request throughput	每秒钟成功处理的平均请求数	成功请求数 / 测试总时长

指标	英文名称	解释	公式
总延迟时间	Total latency	所有成功请求的延迟时间总和	所有成功请求的延迟时间之和
平均延迟	Average latency	从发送请求到接收完整响应的平均时间	总延迟时间 / 成功请求数
平均首 token 时间	Average time to first token	从发送请求到接收到第一个响应标记的平均时间	总首 chunk 延迟 / 成功请求数
平均每输出 token 时间	Average time per output token	生成每个输出标记所需的平均时间（不包含首 token）	总每输出 token 时间 / 成功请求数
平均输出 token 间时延	Average inter-token latency	生成每个输出 token 之间的平均间隔时间	总输出 token 间时延 / 成功请求数
平均输入 token 数	Average input tokens per request	每个请求的平均输入标记数	总输入 token 数 / 成功请求数
平均输出 token 数	Average output tokens per request	每个请求的平均输出标记数	总输出 token 数 / 成功请求数

性能-百分位指标

以单个请求为单位进行统计，数据被分为 100 个相等部分，第 n 百分位表示 n%的数据点在此值之下。

-

P75：统计的颗粒度以 token 为单位，以 DecodeTime 为例，所有请求的 DecodeTime 的 75 分位。

-
-

P90：统计的颗粒度以 token 为单位，以 DecodeTime 为例，所有请求的 DecodeTime 的 90 分位。

-
-

P99：统计的颗粒度以 token 为单位，以 DecodeTime 为例，所有请求的 DecodeTime 的 99 分位。

-
-

SLO_P90：统计的颗粒度以请求为单位，以 DecodeTime 为例，首先每个请求的所有 DecodeTime 取平均值，然后对所有请求的平均 DecodeTime 取 90 分位。

-

指标	名称	业务参考意义
P50	中位数	**标准体验**。一半用户比这个快，一半比这个慢。反映系统在正常情况下的表现。
P75	优良线	**大多数人的体验**。如果在优化系统，先保证 P75 达标。
P90	及格线	**长尾效应的开始**。如果 P90 很高，说明有 10% 的请求已经明显变慢了，需要排查资源是否饱和。
P99	极端情况	**最差体验**。反映系统最脆弱的时刻(如垃圾回收 GC、瞬间高并发等)。

P 值（P75/P90/P99）反映的是**系统底层的稳定性**，而 SLO_P90 反映的是**用户的真实体感**。
百分位业务意义：用于系统压力测试：衡量推理引擎在处理单个 Token 时的极致性能和抖动情况。

参数指标	max	min	P75	P90	SLO_P90	P99
首个 token 平均时延，单位（ms）	首个 token 最大时延，单位（ms）	首个 token 最小时延，单位（ms）	首个 token75 分位时延，单位（ms）	首个 token90 分位时延，单位（ms）	首个 token90 分位时延，单位（ms）	首个 token99 分位时延，单位（ms）
Decode 阶段平均时延，单位（ms）	最大 Decode 阶段时延，单位（ms）	最小 Decode 阶段时延，单位（ms）	75 分位 Decode 阶段时延，单位（ms）	90 分位 Decode 阶段时延，单位（ms）	90 分位每条请求 Decode 阶段平均时延，单位	99 分位 Decode 阶段时延，单位（ms）

参数指标	max	min	P75	P90	SLO_P90	P99
					（ms）	
最后一个token平均时延，单位（ms）	最后一个token最大时延，单位（ms）	最后一个token最小时延，单位（ms）	最后一个token75分位时延，单位（ms）	最后一个token90分位时延，单位（ms）	最后一个token90分位时延，单位（ms）	最后一个token99分位时延，单位（ms）
所有请求最大Decode阶段平均时延，单位（ms）	所有请求最大Decode阶段时延，单位（ms）	所有请求最小Decode阶段时延，单位（ms）	所有请求75分位Decode阶段时延，单位（ms）	所有请求90分位Decode阶段时延，单位（ms）	所有请求90分位Decode阶段时延，单位（ms）	所有请求99分位Decode阶段时延，单位（ms）
请求推理平均时延，单位（ms）	最大请求推理时延，单位（ms）	最小请求推理时延，单位（ms）	75分位请求推理时延，单位（ms）	90分位请求推理时延，单位（ms）	90分位请求推理时延，单位（ms）	99分位请求推理时延，单位（ms）
输入token平均长度	最大输入token长度	最小输入token长度	75分位输入token长度	90分位输入token长度	90分位输入token长度	99分位输入token长度
生成token平均长度	最大生成token长度	最小生成token长度	75分位生成token长度	90分位生成token长度	90分位生成token长度	99分位生成token长度
生成token平均速度，单位（token/s）	最大生成token速度，单位（token/s）	最小生成token速度，单位（token/s）	75分位生成token速度，单位（token/s）	90分位生成token速度，单位（token/s）	90分位生成token速度，单位（token/s）	99分位生成token速度，单位（token/s）
生成字符平均长度	最大生成字符长度	最小生成字符长度	75分位生成字符长度	90分位生成字符长度	90分位生成字符长度	99分位生成字符长度
tokenizer的平均时间，单位（ms）	最大tokenizer时间，单位（ms）	最小tokenizer时间，单位（ms）	75分位tokenizer处理时间，单位（ms）	90分位tokenizer处理时间，单位（ms）	90分位tokenizer处理时间，单位（ms）	99分位tokenizer时间，单位（ms）

参数指标	max	min	P75	P90	SLO_P90	P99
detokenizer 的平均时间，单位（ms）	最大 detokenizer 时间，单位（ms）	最小 detokenizer 时间，单位（ms）	75 分位 detokenizer 处理时间，单位（ms）	90 分位 detokenizer 处理时间，单位（ms）	90 分位 detokenizer 处理时间，单位（ms）	99 分位 detokenizer 时间，单位（ms）
每个 token 平均生成的字符数	-	-	-	-	-	-
所有 token 平均后处理时间，单位（ms）	所有 token 最大后处理时间，单位（ms）	所有 token 最小后处理时间，单位（ms）	所有 token 75 分位后处理时间，单位（ms）	所有 token 90 分位后处理时间，单位（ms）	所有 token 90 分位后处理时间，单位（ms）	所有 token 99 分位后处理时间，单位（ms）
所有 token 平均模型推理时间，单位（ms）	所有 token 最大模型推理时间，单位（ms）	所有 token 最小模型推理时间，单位（ms）	所有 token 75 分位模型推理时间，单位（ms）	所有 token 90 分位模型推理时间，单位（ms）	所有 token 90 分位模型推理时间，单位（ms）	所有 token 99 分位模型推理时间，单位（ms）
Prefill 阶段 batchsize 平均值	最大 Prefill 阶段 batchsize	最小 Prefill 阶段 batchsize	75 分位 Prefill 阶段 batchsize	90 分位 Prefill 阶段 batchsize	90 分位 Prefill 阶段 batchsize	99 分位 Prefill 阶段 batchsize
Decode 阶段 batchsize 平均值	最大 Decode 阶段 batchsize	最小 Decode 阶段 batchsize	75 分位 Decode 阶段 batchsize	90 分位 Decode 阶段 batchsize	-	99 分位 Decode 阶段 batchsize
队列等待时间平均值，单位（μs）	最大队列等待时间，单位（μs）	最小队列等待时间，单位（μs）	75 分位队列等待时间，单位（μs）	90 分位队列等待时间，单位（μs）	-	99 分位队列等待时间，单位（μs）

3.4、 Agent 任务全链路-成本指标

芯片指标

监控层级	观测项	含义	示例
芯片重点指标	内存带宽利用率 MBU	衡量解码（Decode）阶段对 HBM（高带宽内存）利用效率的指标。由于智能体推理极度依赖内存读取，MBU 往往比 MFU 更能代表推理芯片的真实性能瓶颈。	
	算力利用率 MFU	实际计算量与理论峰值算力的比率。在智能体长序列输入下，如何通过硬件指令优化提升预填充阶段的 MFU 是工程	

监控层级	观测项	含义	示例
		重点	
	Throughput 关注成本、功耗	吞吐量，指的是单位时间内处理的任务数，即每秒处理的 token 数。	
	Goodput	有效吞吐量	
	每秒处理字符数 TPS	分为系统 TPS 和用户 TPS。系统 TPS 衡量服务器的总吞吐量，而用户 TPS 反映单用户体验到的速度。	

<table>
<tr><th>监控层级</th><th>观测项</th><th>含义</th><th>示例</th></tr>
<tr><td></td><td>推理每token焦耳数</td><td>用于衡量推理单位下的能耗最小指标</td><td>
<table>
<tr><th>年份</th><th>2016</th><th>2018</th><th>2020</th><th></th></tr>
<tr><td>GPU</td><td>“Pascal” P100</td><td>“Volta” V100</td><td>“Ampere” A100</td><td></td></tr>
<tr><td>峰值(TFLOPs)</td><td>19</td><td>130</td><td>620</td><td></td></tr>
<tr><td>训练和推理精度</td><td>FP16</td><td>FP16</td><td>FP16</td><td></td></tr>
<tr><td>推理每token焦耳数</td><td>17000</td><td>1200</td><td>150</td><td></td></tr>
<tr><td>训练所需电力(GW/小时)</td><td>1000</td><td>140</td><td>40</td><td></td></tr>
<tr><td>GPU 架构图</td><td> 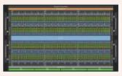 </td><td> 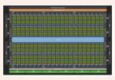 </td><td> 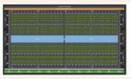 </td><td> </td></tr>
</table>
</td></tr>
<tr><td></td><td>显存</td><td>是 GPU 用于存储数据和纹理的专用内存，与系统内存（RAM）不同，显存具有更高的带宽和更快的访问速度。显存的大小和性能直接影 GPU 处理大规模数据的能力。</td><td></td></tr>
<tr><td></td><td>功耗</td><td>即功率损耗，指单位时间内的</td><td></td></tr>
</table>

监控层级	观测项	含义	示例
		能量消耗，反应消耗能量的速率，单位是瓦特（W）。	
	显存带宽	作为GPU与显存之间数据传输的桥梁；显存带宽=显存位 × 显存频率	
性能与稳定性监控	QPS	QPS（Queries Per Second）：每秒处理的请求数量，反映系统负载。	/v1/completions
	请求成功率	成功返回结果的请求占比，用于评估服务健康度。	200/400
	响应时间（RT）	包括非流式响	Chrome/HTTP Client

监控层级	观测项	含义	示例
		应的整体延迟和流式响应的首包延迟（Time to First Token），直接影响用户体验。	
	耗时	请求的处理时间。	1 s
资源消耗与成本分析	Token消耗数/s	实时监控每秒输入、输出及总Token消耗速率。	
	按模型维度的Token使用统计	识别高成本模型的使用频率，辅助模型选型优化。	
	按消费者维度的Token使用统计	实现“谁使用、谁负责”的成本分摊机制，	

监控层级	观测项	含义	示例
		支持预算控制与配额管理。	

单节点-网络指标

指标名称	指标说明	监控周期（原始指标）
节点名称	集群的节点名称。	180s
网卡名称	网卡的名称。	60s
网卡状态	网卡状态（up/down）。	60s
网卡速度（Mbps）	网卡速度。	60s
接收包数	网卡接收数据的包数。	60s
发送包数	网卡发送数据的包数。	60s
接收丢包数	网卡接收时丢弃的数据包数。	60s
接收速率（KB/s）	网卡接收数据的速率。	60s
发送速率（KB/s）	网卡发送数据的速率。	60s

网络-关键性能指标评估

指标	监测要点	业务参考意义
点对点带宽	两个特定节点之间的最大传输速率	
聚合带宽	系统中所有节点同时通信时能达到的总带宽	
剖分带宽	网络对半分割后，两半之间可用的总带宽，衡量全局通信能力的关键指标。	
有效带宽	在特定通信模式（如 AllReduce）下，应用程序实际感受到的带宽，通常会低于理论峰值带宽，受算法、协议开销、拓扑等影响。	
网络延迟	消息从发送端开始发送到接收端开始接收所需的时间，通常测量单向延迟或更常用的往返时间（Round-Trip Time，RTT），并用微秒（μs）表示。	对需要频繁同步或传输小消息的操作（如分布式锁、某些控制信令、小批量梯度的同步）影响显著。低延迟可以减少等待时间，提高计算资源的利用率。
延迟	消息从发送端开始发送到接收端开始接收所需的时间，通常测量单向延迟或更常用的往返时间（Round-Trip Time，RTT），并用微秒（μs）表示。	对需要频繁同步或传输小消息的操作（如分布式锁、某些控制信令、小批量梯度的同步）影响显著。低延迟可以减少等待时间，提高计算资源的利用率。
点对点延迟	两个特定节点间的最短通信延迟	
集体操作延迟	完成一次集体通信（如 AllReduce）所需的总时间。	
磁盘IOPS	模型加载/数据读取吞吐量	
带宽利用率	南北向流量峰值	静态阈值：≤物理带宽 80%

指标	监测要点	业务参考意义
显存带宽使用率		
消息速率	单位时间内可以处理（发送和接收）的消息数量，通常以 MPPS (Millions of Packets Per Second) 或 MOPS (Millions of Operations Per Second) 表示	对于涉及大量小消息的通信模式很重要
计算通信重叠度	在执行计算任务的同时进行网络通信的能力和程度	高效的重叠可以隐藏通信延迟，提高整体吞吐量。这需要硬件（如独立的传输引擎）、软件（异步操作支持）和算法（流水线设计）的协同。
扩展效率	当增加计算资源（如 GPU 数量）时，性能提升的比例。理想情况下是线性扩展。	衡量系统并行处理能力和网络支撑能力的关键。低扩展效率通常意味着通信瓶颈随着规模增大而日益严重。

算力节点网络间监控指标（RoCE 网络）

指标名称	说明	单位	取值范围
NPU 网络健康情况	NPU 卡的 RoCE 网卡的 IP 地址连通情况	-	0：网络健康状态正常非0：网络状态异常
NPU 网口 link 状态	NPU 卡的对应网口 link 状态	-	0：UP1：DOWN
NPU 网卡上行速率	NPU 卡内网卡的上行速率	MB/s	≥0
NPU 网卡下行速率	NPU 卡内网卡的下行速率	MB/s	≥0
MAC 发送 pause 帧总数	NPU 卡对应 MAC 地址发送的 pause 帧总报文数	count	≥0

指标名称	说明	单位	取值范围
MAC 接收 pause 帧总数	NPU 卡对应 MAC 地址接收的 pause 帧总报文数	count	≥0
MAC 发送 pfc 帧总数	NPU 卡对应 MAC 地址发送的 PFC 帧总报文数	count	≥0
MAC 接收 pfc 帧总数	NPU 卡对应 MAC 地址接收的 PFC 帧总报文数	count	≥0
MAC 发送坏包总数	NPU 卡对应 MAC 地址发送的坏包总数	count	≥0
MAC 接收坏包总数	NPU 卡对应 MAC 地址接收的坏包总数	count	≥0
RoCE 发送坏包总数	NPU 卡内 RoCE 网卡发送的坏包总数	count	≥0
RoCE 接收坏包总数	NPU 卡内 RoCE 网卡接收的坏包总数	count	≥0
NPU RoCE 发送总报文数	该指标描述 NPU RoCE 发送的总报文数	count	≥0
NPU RoCE 接收总报文数	该指标描述 NPU RoCE 接收的总报文数	count	≥0
NPU RoCE 的重传报文数	该指标描述 NPU RoCE 发送的重传的报文数量统计	count	≥0

五：Agent 场景存储数据标准（场景化标准输入格式）

核心输出-输出 Agent 和竞品厂商集群性能相关调研报告、Aaas 平台对场景的还原部署和验证

① 监控产业界竞品技术动态，分析竞品集群测试负载方案、核心能力及技术优势，为团队提供前沿技术参考与竞争策略支持。

② 深度调研海内外 Agent 主流场景产品，并将使用体验转化为评测与产品改进思路

③ 深度调研热点大模型、智能体应用场景扩展（业界典型的热点模型的调研，部署，集成，最佳实践。以及所这些模型在先进算力平台/成熟推理框架/成熟推理编排方案下的竞争力参照指标（时延，TPS，上下文长度，TTFT，TTOP，并发、算力成本、配套成本等））

数据输入标准-测试

七、推进节点计划-2026/9/1

评测集格式输出-测试作为接收方，评测集格式的定义
存储：过程日志、对话内容、任务结果、轨迹回放、统计指标、对比评估报告
存储过程数据：Iaas、Maas、LLM、Agent 四层汇总
先进算力对比：4090、HW、 X6000s、N800
调研工具：langfuse、k6、普罗米修斯（Iaas）、playwright、granfa、EvalScope
Agent 前后任务版本比对：同一个任务不变、中间过程输入变量、硬件等